



Masterarbeit

Gewinnung von Nutzschaall in komplexen Geräuschumgebungen

Kilian Mütz B.Sc.
Prof. Dr. Manfred Rössle

Hochschule Aalen
Fakultät Wirtschaft und Gesundheit

Wirtschaftsinformatik
Master of Science

8. September 2026

Erklärung

Ich versichere hiermit an Eides statt, dass ich die hier vorliegende Arbeit selbständig verfasst habe. Jede Stelle, an der wörtlich oder inhaltlich auf das Gedankengut anderer zurückgegriffen wurde, habe ich kenntlich gemacht. Weder die gesamte Arbeit noch Teile der Arbeit lagen jemals einer Prüfungsbehörde vor.

Aalen, 8. September 2026



Unterschrift, Kilian Mütz

Schall ist ein komplexes Ereignis,
fürs Ohr weniger,
für die Software allemal.

— Heiner Uber, *die ZEIT* (1994)¹

¹Uber, 1994.

Zusammenfassung

Stark komprimierte Zusammenfassung von Ziel, Methodik, der wichtigsten Ergebnisse und Diskussion der Arbeit + Keywords vergeben

Das Abtsgmünder Ingenieurbüro Röwaplan entwickelt mit SIPREMA ein Edge Device für Predictive Maintenance, das Maschinengeräusche erfasst und akustische Anomalien mittels Machine Learning erkennt.

Danksagung

Begin acknowledgments. Die vorliegende Arbeit ist als Masterarbeit im Studiengang Wirtschaftsinformatik an der Hochschule Aalen unter Prof. Dr. Manfred Rössle erarbeitet

Prof Rössle Michi Werkmann Heiko Rössel

Alex, Elena und Tobi

Inhaltsverzeichnis

Erklärung	i
Widmung	ii
Zusammenfassung	iii
Danksagung	iv
Abkürzungen	ix
Notation	x
Abbildungen	xi
Tabellen	xii

I	Einführung	1
1	Einleitung	2
1.1	Motivation	2
1.2	Problemstellung	3
1.3	Gang der Arbeit	12
2	Grundlagen	13
II	Literaturrecherche	30
3	Methodik	31
3.1	Suchraum	31
3.2	Suchstrategie	32
3.3	Auswahlkriterien	32
4	Ergebnisse	35
4.1	Stand der Forschung	35
4.1.1	Nicht anwendbare Verfahrensklassen	37
4.2	Begründete Auswahl	38
4.2.1	Ausschlüsse nach den Auswahlkriterien	39
4.2.2	Bestimmung des Klassensiegers	40
4.2.3	Ausgewählte Verfahren	42
4.3	Implementierung	43
4.3.1	Physikalisch orientierte Verfahren	44
4.3.2	Statistische Spektralschätzung	46
4.3.3	Struktur- und Faktorisierungsverfahren	49
4.3.4	Adaptive Modenzerlegung	52
III	Experiment	54
5	Methodik	55
5.1	Aufbau	55
5.1.1	Versuchsplan und Pegelstufen	58

5.1.2	Verarbeitungskette nach SIPREMA-Vorbild	59
5.2	Bewertung	60
5.2.1	Zielgröße	60
5.2.2	Bewertungskette	61
5.2.3	Vergleichsbedingungen	61
5.2.4	Metriken	62
5.2.5	Eignung für den Edge-Betrieb	62
5.2.6	Absicherung der Ergebnisse	63
5.2.7	Erwartungen	63
6	Ergebnisse	64
6.1	x	64
6.2	y	64

IV Diskussion	65
7 Interpretation	66
8 Einordnung	67
8.1 Erkenntnissgewinn	67
8.2 Limitationen	67
8.3 Ausblick	68
8.3.1 Einschränkungen des Aufbaus	69
Literatur	74
A Anhang	81
A.1 Suchstring-Katalog	81
A.2 Datenbanken-Ergebnisse	83
A.3 Ergebnisse der Rückwärtssuche	83
A.4 Bewertung der identifizierten Verfahren	84
A.5 Verfahrenscodes	85

Abkürzungen

KI Künstliche Intelligenz

.. ..

Notation

x Eingangssignal

Abbildungen

2.1	Enter Caption	13
2.2	Enter Caption	15
2.3	Enter Caption	15
2.4	Enter Caption	16
2.5	Enter Caption	18
2.6	Enter Caption	19
2.7	Enter Caption	19
2.8	Enter Caption	20
2.9	Enter Caption	21
2.10	Enter Caption	21
2.11	Enter Caption	22
2.12	Enter Caption	23
2.13	Enter Caption	25
2.14	Enter Caption	25
2.15	Enter Caption	26
2.16	Enter Caption	28

Tabellen

4.1	Zerlegungsgüte je Verfahren am Referenzsignal <code>observ_1.wav</code> . ε_{rek} : Rekonstruktionsfehler, ρ : Komplementarität (Betrag der Korrelation zwischen Nutz- und Störschall). Kleinere Werte sind besser. Fett: niedrigstes ρ je Klasse bei eingehaltener Rekonstruktion.	41
4.2	Für die vertiefte Implementierung ausgewählte Verfahren je Klasse. Der Klassensieger nach dem Zerlegungskriterium (Abschnitt 4.2.2) ist mit $\star$ gekennzeichnet; ergänzend übernommene, komplementär trennende Verfahren ohne Markierung.	43
5.1	Herbeigeführte Anomaliezustände	56
5.2	Stör- und Hintergrundgeräusche	57
5.3	Aufnahmeliste für die Labormessung	58
5.4	Merkmale des SIPREMA-Merkmalvektors	60
5.5	Bedingungen des Verfahrensvergleichs	61
A.1	Suchstring-Katalog der strukturierten Literaturrecherche	81
A.2	Bewertung der identifizierten Verfahren anhand der Auswahlkriterien K1–K4. ✓ = erfüllt, ~ = bedingt erfüllt, ✗ = nicht erfüllt. Ein Verfahren gilt als Kandidat, wenn es alle Kriterien K1–K4 erfüllt (fett hervorgehoben). Die Spalte „Auswahl“ kennzeichnet mit ✓ jene Verfahren, die als Vertreter ihrer Klasse für die vertiefte Implementierung ausgewählt wurden (vgl. Abschnitt 4.2).	84

Teil I

Einführung

Einleitung

1.1 Motivation

Ricardo Diez-Hochleitner †, Ehrenpräsident des Club of Rome, bezeichnet die immer umfangreichere, computerbasierte Analyse von Informationen als einen Irrweg, um Komplexität zu bewältigen. Die Ansammlung von Informationen im Sinne von „Big Data“ führt nicht zu einem besseren Verständnis der Welt, sondern trägt als Informationsflut zum Unverständnis bei. Vielmehr sei es sinnvoll, die Realität anhand von Mustern mit gewissen Unschärfen zu erfassen, um Komplexität beinahe intuitiv erklärbar zu machen. Dieses Vorgehen bezeichnet er als **kybernetischen Ansatz** Vester, 2002. Auch in dieser Arbeit soll aus einem komplexen System heraus, mit minimalem Aufwand ein relevantes Muster isoliert werden. - Aufwendiger Weg: Algorithmen mit großen Datenmengen die alle Störgeräusche kennen oder ML-Algorithmen die diese lernen. Kybernetischer Weg: Algorithmus der das Muster des Maschinengeräuschs kennt/lernt und universell anwendbar ist- Ist das möglich oder eine **kybernetische Utopie**? Offene Frage, die du stellen kannst: Ist ein universeller Algorithmus, der nur das Muster des Maschinengeräuschs kennt/lernt, möglich — oder eine „kybernetische Utopie“? (Guter Spannungsbogen für Einleitung → Fazit.)

Die Sicherstellung einer hohen technischen Verfügbarkeit von Maschinen und Anlagen ist ein zentrales Ziel moderner Instandhaltung. Ungeplante Ausfälle verursachen neben Reparaturkosten häufig auch erhebliche Prozess- und Stillstandskosten. Vor diesem Hintergrund gewinnen Condition Monitoring und Predictive Maintenance an Bedeutung, da beide Ansätze darauf abzielen, Zustandsveränderungen frühzeitig

zu erkennen und Wartungsmaßnahmen vorausschauend statt reaktiv durchzuführen (Kamat u. a., 2020).

Ein Ansatz der Zustandsüberwachung besteht in der Analyse akustischer Signale. Technische Objekte erzeugen im Betrieb charakteristische Geräuschemuster, die Rückschlüsse auf ihren Zustand zulassen. Veränderungen durch beginnende Defekte können sich dabei akustisch bemerkbar machen, bevor ein Ausfall eintritt. Akustische Überwachung gilt als praxisnah, da sie sich vergleichsweise einfach nachrüsten lässt und im Gegensatz zu vielen schwingungsbasierten Verfahren ohne direkten Eingriff in die Maschine auskommt (Hirschmiller u. a., 2023a).

SIPREMA positioniert sich als akustikbasiertes Edge-System für Condition Monitoring und Predictive Maintenance. Das System erfasst Maschinengeräusche kontinuierlich, analysiert diese lokal und stellt die Ergebnisse über ein Dashboard bereit. SIPREMA wird dabei als „digitales Ohr des Instandhalters“ beschrieben (Röwaplan AG, 2026).

Die vorliegende Masterarbeit greift diesen Kontext auf und fokussiert die Frage, mit welchen Verfahren sich aus einem akustisch überlagerten Gesamtsignal ein **Nutzschall** gewinnen lässt, der sich dem maschinenbezogenen Objektschall annähert und eine geeignete Grundlage für die **Machine-Learning-basierte Zustandsbewertung** bildet.

1.2 Problemstellung

Betrachtetes System Im Zentrum des betrachteten Systems steht das **überwachte Objekt** O . Das kann eine Maschine wie eine Pumpe, eine technische Anlage, ein sonstiges technisches Objekt oder ein zu überwachender Raum sein.

Im Betrieb erfüllt das Objekt O seine technische Funktion, indem es zugeführte Energie in die Wirkung umwandelt, für die es konstruiert wurde. Dabei wirken Kräfte auf Bauteile, angrenzende Strukturen und beteiligte Materie ein. Es entstehen Schwingungen, die sich auf die umgebende Luft übertragen und sich so im Raum als **Schallwellen** ausbreiten (Lerch u. a., 2009). Eine Pumpe setzt beispielsweise ein Fluid unter Druck und in Bewegung, wodurch charakteristische Strömungs- und Reibungskräfte entstehen (Piepiorka u. a., 2019).

So entsteht im umgebenden Raum ein für den Betriebszustand des Objekts **charakteris-**

tisches akustisches Muster. Es bildet den für die Zustandsüberwachung relevanten Signalteil Jombo u. a., 2023. Dieser wird im Folgenden als **Objektschall** $o(t)$ bezeichnet.

Der Objektschall tritt jedoch nicht isoliert auf. Im Raum entstehen weitere, relativ konstante akustische Anteile, etwa durch andere Maschinen, Raumhall, Luftströmungen oder Straßenverkehr. Diese werden im Folgenden als **Hintergrundscharll** $h(t)$ bezeichnet.

Darüber hinaus treten unregelmäßige akustische Ereignisse wie Gespräche, Schritte, Türgeräusche oder andere kurzfristige Störgeräusche auf. Diese werden im Folgenden als **Fremdschall** $f(t)$ bezeichnet Pichler u. a., 2024.

Damit ergibt sich im beobachteten Raum ein **akustisches Gesamtsignal** $x(t)$, das sich aus Objektschall, Hintergrundscharll und Fremdschall zusammensetzt:

$$x(t) = o(t) + h(t) + f(t) \quad (1.1)$$

- Das bedeutet in dieser Arbeit nehme ich ein additives Signalmodell an. In der Regel die Verarbeitung einer Mono Tonspur. Alle Töne sind also auf einer TOnspur und nicht auf zwei (Stereo) oder mhereren obwohl das grundsätzlich möglich ist. - Hier auch einen ersten Print oder eine Skizze machen. Das Gesamtsignal ist blau. Der Objektschall grün. Der Störschall rot. Nutzscharll wird dann türkis. - Für den Fokus dieser Arbeit (Untersuchung rotierender MASchinen): vor allem Untersuchung rotierender MASchinen Annahme quasi stationäreren / zyklischen Hintergrundscharlls und dynamischem Störschall

Hardware als Beobachter des Systems - Abkürzung für Beobachter einführen ab nun "Boxöder "Beobachter"

Die Erfassung und Verarbeitung dieses akustischen Signals kann auf unterschiedliche Weise erfolgen. Im Folgenden wird der Einsatz eines **Edge Devices** betrachtet, bei dem der gesamte Prozess direkt auf einer lokalen Recheneinheit ausgeführt wird, beispielsweise auf Basis eines Raspberry Pi mit einer Zusatzplatine als Audio-IO-Board Hirschmiller u. a., 2023a.

Das akustische Gesamtsignal $x(t)$ wird sensorisch durch **Mikrofone** erfasst. Die Schall-

wellen werden in ein **analoges elektrisches Signal** $u_a(t)$ umgewandelt. Je nach Auslegung kann der erfasste Frequenzbereich über den menschliche wahrnehmbaren hinausgehen. Im Anschluss erfolgt gegebenenfalls eine Aufbereitung und Verstärkung des kontinuierlichen analogen Signals in einem analogen Frontend (AFE) zu $u_v(t)$. Dieses wird durch einen Analog-Digital-Wandler (ADC) in ein diskretes **digitales Signal** $x_d[n]$ umgewandelt **MalcotaviMEMS**. Variablen für den Informationsumfang sind hierbei die Abtastrate und Bittiefe **adobe_digitizing_audio**. Der Signalfluss lässt sich wie folgt darstellen und auf alle Signaleile übertragen:

-welcher genaue Frequenzbereich wird erfasst

$$x(t) \rightarrow u_a(t) \rightarrow u_v(t) \rightarrow x_d[n] \quad (1.2)$$

Für die Analyse wird das digitalisierte Signal $x_d[n]$ in der **Vorverarbeitung** in aufeinanderfolgende **5-Sekunden-Segmente** zerlegt. Das k -te Segment wird im Folgenden mit $x_k[n]$ bezeichnet.

$$x_d[n] \rightarrow x_k[n] \quad (1.3)$$

Im nächsten Analyseschritt, der **Merkmalsextraktion**, werden aus jedem Segment **zeitbasierte Merkmale** z_k und **frequenzbasierte Merkmale** f_k berechnet. Die zeitbasierten Merkmale beschreiben beispielsweise die Lautstärke oder Schwankung des Signals. Die frequenzbasierten Merkmale werden nach Umwandlung des Segments in den Frequenzbereich mittels **Fourier-Transformation** bestimmt und zeigen etwa die Energie einzelner Frequenzbänder oder die Bandbreite des Spektrums **bracewell2000fourier**. Eine mögliche Darstellung im Frequenzbereich erfolgt beispielsweise durch **Mel-Spektrogramme zhang2021acoustic**.

Die so gewonnenen Merkmale aus beiden Merkmalsräumen bilden gemeinsam den Merkmalsvektor m_k des k -ten Segments.

$$m_k = (z_k, f_k) \quad (1.4)$$

Darauf aufbauend erfolgt die Modellierung mit einem **unüberwachten Machine-Learning-Algorithmus zur Anomalieerkennung**, etwa einem **Isolation Forest**. In einer siebentägigen Lernphase wird zunächst der akustische Normalzustand erfasst. Abweichungen von diesem Referenzzustand können anschließend als Anomalien erkannt werden **LiuIsolationForest**.

Der Merkmalsvektor wird anschließend mit einem Machine Learning Algorithmus zur Anomalieerkennung (Welcher ML Algorithmus? Random Forest?) analysiert. In einer siebentägigen, unüberwachten Lernphase wird der akustische Normalzustand für die beobachtete Maschine vom Algorithmus erlernt. Für das Anlernen ist ein möglichst fehlerfreier Ausgangszustand der Maschine besonders geeignet, da dieser den akustischen Basiszustand definiert, von dem spätere Veränderungen erkannt werden. k Merkmale-1 Mittelwert Frequenzbandenergien Minimum Spektrogramm Maximum Mel-Spektrogramm Standardabweichung MFCC RMS-Wert Spektrale Zentroiden Anzahl der Peaks Bandbreite des Spektrums Zeitbasierte $z_k = (z_{k,1}, z_{k,2}, \dots, z_{k,p})$ Frequenzbasierte $f_k = (f_{k,1}, f_{k,2}, \dots, f_{k,q})$ m_k Abweichungen von diesem werden als Anomalien und damit als schadhafte Veränderungen klassifiziert. Geräuschmuster, die von diesem gelernten Zustand abweichen oder nur selten auftreten, werden mit erhöhter Wahrscheinlichkeit als Anomalien eingestuft. Erkennung von Regulären oder Nicht regulären Zuständen. Je homogener und stabiler die Geräuschkulisse ist, desto einfacher ist in der Regel das Training; heterogene Umgebungen mit stark wechselnden Nebengeräuschen erhöhen dagegen die Komplexität der Modellbildung. Eine konkrete inhaltliche Benennung der erkannten Anomalie erfolgt im Grundansatz zunächst nicht automatisch, sondern erst im weiteren Verlauf durch manuelle Klassifikation oder durch den Aufbau zusätzlicher Wissensbestände, wie sie in erweiterten Systemvarianten vorgesehen sein können. Damit richtet sich die Analyse nicht nur auf einzelne auffällige Ereignisse, sondern insbesondere auch auf langsame Trendänderungen im akustischen Muster über Tage oder Monate. Relevante Veränderungen können sich etwa in Form von Reibung, unerwünschten Kontakten, mechanischen Impulsen, Lockerheiten, periodischen Anregungen rotierender Komponenten oder einer allgemeinen Zunahme mechanischer Belastung äußern. Auf diese Weise lassen sich beginnende Zustandsänderungen erkennen, noch bevor ein offensichtlicher Ausfall eintritt. z.B. auch Schleifgeräusch bei einem stumpf werdenden Drehmeißel. Wäre es

besser Schwingungen zu überwachen ? Ja ! Aber das ist sehr komplex und speziell zu messen. Akustische Überwachung kann ohne Veränderung an der Maschine platziert wird im Gegensatz zu z.B. Schwingungssensoren. Auch Kompressoren und Motorantriebe werden überwacht. Und Lagerverschleiss am Prüfstand. Auch CNC Maschinen. Aber deutlich aufwendigeres Training.

Die Ergebnisse der Analyse werden lokal gespeichert und über einen Webserver in einem **Dashboard** für den Nutzer visualisiert und bereitgestellt Kamat u. a., 2020 Röwaplans AG, 2026.

Die Ergebnisse der Analyse werden über einen auf der SIPREMA Box laufenden Webserver in einem lokalen Dashboard bereitgestellt, das als zentrales „Cockpit“ des Systems dient. Auf dieses Dashboard kann mit einem gewöhnlichen Webbrowser zugegriffen werden. Es visualisiert die Zustandsbewertung der überwachten Maschine und hebt erkannte Anomalien farblich sowie zeitlich markiert hervor. Ergänzend unterstützt das System eine proaktive Alarmierung per E-Mail, sodass auffällige Zustandsänderungen nicht nur im Dashboard sichtbar, sondern auch aktiv gemeldet werden. Der Nutzer kann die erkannten Anomalien im Dashboard im Detail betrachten und sich sowohl die auffälligen Geräuschabschnitte als auch den zugehörigen Normalzustand zum Vergleich anhören. Anschließend besteht die Möglichkeit, die erkannte Auffälligkeit entweder als tatsächliche Anomalie oder als Bestandteil des Normalzustands zu klassifizieren. Auf diese Weise wird das Dashboard nicht nur zur Visualisierung, sondern auch zur Rückkopplung in die Zustandsbewertung genutzt und unterstützt damit die fortlaufende Verbesserung des Algorithmus.

- Zur Architektur - Wir verwenden Raspberry Pi als Sound Software und dieses MEMS Mikrofon: <https://www.seeedstudio.com/ReSpeaker-2-Mics-Pi-HAT.html>
- Der Raspberry Pi 4b besitzt eine HAT Zusatzplatine mit zwei MEMS Mikrofonen die jedoch nur x cm auseinanderliegen und damit ein Einzelkanal sind.
- Kein Analogfrontend von dem Michael was weiß. Aber mal das Mikrofon checken und dazu recherchieren
- Läuft auf SIPREMA Raspberry Pi OS - mit Desktop oder nur Kommandozeile(Lite)?
- .wav files ? (mono oder stereo)

- Einschränkung auf rotierendes Equipment / Maschinen
- Konnektivität über LAN-Anschluss oder LTE-Stick vorsehen.
- 128 Millisekunden Fenster mit schrittweise Verschiebung von 32 Millisekunden für ein 5 Sekunden Frame Technisch lässt sich ein solcher Ansatz beispielsweise mit einer lokalen Recheneinheit wie einem Raspberry Pi 5 in einem 3D-gedruckten oder gefrästen Gehäuse realisieren. Die Stromversorgung erfolgt dabei typischerweise über ein Netzteil, die Netzwerkanbindung über einen LTE-Stick oder eine LAN/Ethernet-Verbindung. Für die Audioanbindung kann eine Zusatzplatine eingesetzt werden, die als Audio-/IO-Board dient. Siprema hat zwei Mems Mikrofone und kann daher triangulieren woher ein Geräusch kommt bisher aber sagen ob von links oder rechts
- So kann SIPREMA Maschinengeräusche kontinuierlich aufzeichnen und analysieren. Die softwareseitige Analyse erfolgt auf der CPU des Rechners unter Nutzung von RAM und Speicher. Die Software umfasst neben der Signalverarbeitung und Analyse auch eine lokale Datenhaltung. Nach Aussagen aus dem Entwicklungskontext existieren dabei getrennte Datenbereiche für geräuschbezogene Informationen und für KI-bezogene Informationen. Dadurch können sowohl Audiodaten zur späteren Wiedergabe als auch Analyse- und Zustandsinformationen für Bewertung, Vergleich und Interaktion im Dashboard bereitgestellt werden. Variablen der Rechnerarchitektur - mehr RAM / CPU = schnellere Berechnung? usw 3. Die

YAMNet (Gemmeke u. a., 2017; Hershey u. a., 2017) ist, ein von Google Research entwickeltes vortrainiertes neuronales Netz zur Audioereignisklassifikation. Es basiert auf der MobileNetV1-Architektur und wurde auf dem AudioSet-Datensatz mit über 1,5 Millionen annotierten YouTube-Audioclips trainiert, um 521 Klangklassen zu erkennen, darunter Maschinengeräusche, Umgebungsgeräusche und Sprache. Aufgrund seiner kompakten Architektur mit rund 3,7 Millionen Parametern ist YAMNet für den Einsatz auf Edge Devices geeignet und wird gegenwärtig im SIPREMA-System eingesetzt, um Störgeräusche in aufgezeichneten Audiosegmenten zu erkennen. Wird ein Störgeräusch detektiert, wird das betroffene Geräuschsegment als fehlerhaft markiert und verworfen. Dieser Ansatz löst das Grundproblem jedoch nicht, da nützliche Maschinendaten unwiederbringlich verloren gehen. Die vorliegende Arbeit verfolgt deshalb eine andere

Strategie. Anstatt kontaminierte Segmente zu verwerfen, soll der Nutzschall vom Störschall getrennt werden, sodass das Maschinensignal auch unter Störeinfluss für die Anomalieerkennung erhalten bleibt. Y

Abtastrate A heist wie oft wird das Signal pro Sekunde abgetastet / gemessen - eine Messung ist ein Sample

In der Vorverarbeitung wird das digitalisierte Audiosignal in Fünf- $x_d[n]$ Sekunden-Segmente zerlegt $x_k[n] \mid x_d[n] \rightarrow x_k[n]$ wobei das k -te Zeitsegment bezeichnet. $x_k[n]$ In der Feature Extraction soll aus den Segmenten der Nutzschall destilliert werden. Dazu werden aus den Zeitsegmenten zunächst zeitbasierte Merkmale z_k berechnet, die insbesondere Lautstärke, Amplitudenverlauf und zeitliche Schwankungen des Signals beschreiben. $z_k = z(x_k[n])$ Zusätzlich werden die Segmente mittels Fourier-Transformation in einzelne Frequenzbereiche zerlegt. $X_k = F(x_k[n])$ um daraus frequenzbasierte Merkmale zu berechnen. $f_k = f(X_k)$ Insgesamt werden so über 100 Merkmale in zwei Merkmalsräumen berechnet, die das Segment beschreiben und das charakteristische Muster des Nutzschalls gegenüber Hintergrund- und Störgeräuschen hervorheben sollen. Es ergibt sich der Merkmalsvektor $m_k = (z_k, f_k)$ des k -ten Segments.

Merkmale dann als Tabelle:

Zeitbasierte $z_k = (z_{k,1}, z_{k,2}, \dots, z_{k,p})$ Mittelwert Minimum Maximum Standardabweichung RMS-Wert Anzahl der Peaks

Frequenzbasierte $f_k = (f_{k,1}, f_{k,2}, \dots, f_{k,q})$ Frequenzbandenergien Spektrogramm Mel-Spektrogramm MFCC Spektrale Zentroiden Bandbreite des Spektrums

- die Merkmale sind noch nicht vollständig, es werden auch nicht immer alle oder die gleichen Merkmale verwendet.

Nutzen und Wirkung: Der Nutzer von SIPREMA kann somit den akustischen Zustand eines Raums überwachen, in welchem SIPREMA platziert ist. Eine Anomalie wird als Alarm auf dem Dashboard angezeigt - Instandhalter kann es sich aus dem HomeOffice anhören, klassifizieren und ggf. hinfahren Alarm der proaktiv Reparaturbedarf impliziert (z.B. Mailalarm)

Entweder zur gesamten Raumüberwachung oder zur Detailüberwachung sehr nah an

einer Maschine Wie der Instandhalter früher den Zollstock an die Maschine und an das Ohr gehalten hat um Schwingungen zu erkennen.

Unterstützung und Ersetzen der Instandhalter - zu solchen Kontakt aufnehmen und befragen. (SIPREMA hört 24/7 zu und kann das sogar noch besser) Der Instandhalter bekommt dann einen Alarm wenn die Box eine Anomalie erkennt. Dann kann er aus dem HomeOffice heraus die Anomalie anhören und klassifizieren um Sie besser zu machen. Wenn es sich um ein Problem handelt kann er hinfahren. Vom Reagieren zum Vorbeugen

Systemreferenzen Über die reinen Trennverfahren hinaus belegen industrielle Systemreferenzen die praktische Relevanz akustischer Zustandsüberwachung. Das Fraunhofer IDMT (Fraunhofer Institut für Digitale Medientechnologie IDMT, 2023; Grollmisch u. a., 2019) definiert mit der Industrial Sound Analysis ein eigenes Forschungsfeld; kommerzielle Plattformen wie CochL.Sense (Cochl Inc., 2025) und Sound Genetics (Sound Genetics Inc., 2025) sowie Edge-Ansätze auf Smartphone- bzw. Raspberry-Pi-Basis (Hirschmiller u. a., 2023b; Yamato u. a., 2017) zeigen die Machbarkeit auf ressourcenbeschränkter Hardware. Diesen Systemen ist jedoch gemeinsam, dass sie Klassifikation und Anomalieerkennung adressieren, ohne ein explizites Signaltrennverfahren zu beschreiben — die eigentliche Trennung von Nutz- und Störschall bleibt offen.

Dann Konstruktion eines eigenen perfekt geeigneten Edge devices uch eine Signaltrennung mittels KI Modellen wie GPT und Claude hat gut funktioniert, die Modelle nutzten aber stets klassische Algorithmen wie HPSS und NMF

Plan B ?: in KI Modell antrainieren welches typische Fehlerzustände lernt und dadurch auch bei anderen Maschinen wiedererkennt - Noise Intel (Unsupervised Clusteranalyse ? Classification anhand von Merkmalen ?) Das typische Geräusch der Maschine oder des Maschinentyps lernen ? - explorativ rumsuchen experimentieren

Forschungsfokus / Forschungslücke

- Eingrenzen auf SIPREMA Kontext. Edge Device. Einzelkanal. Begrenzte Ressourcen. Das aktuell verwendete Mikrofon.

- Eingrenzen auf industriellen Kontext von Maschinengeräuschen ggf. nur auf rotierende Maschinen, ggf. auch nur auf bestimmten Störschall
- Eingrenzen auf rotierende Maschinen (Pumpen, Förderbänder, Lüfter, alles mit motor ?, Windräder usw.? aber unbekannte Drehzahl
- Ist es überhaupt möglich den Nutzschall robust aus dem komplexen Gesamtsignal abzugrenzen oder ist das eine kybernetische Utopie ?
- Ein Teilproblem Bisher wird Sprache erkannt, wird diese automatisch weggefiltert und das Snippet kann nicht verwendet werden womit Geräusche fehlen. Besser wäre es das zuverlässig zu trennen. Ggf. Fokus ein auf Sprache legen? Also nur Sprache und Geräusch trennen wäre auch schon ein Win. Dazu wird das vortrainierte Modell "YAMNet" genutzt. YAMNet erkennt Menschliche Sprache als Störgeräusch und entfernt die Aufnahme mit Sprache: Problem - dieses Frame kann gar nicht analysiert werden da es nicht getrennt wird sondern ganz weggeschmissen - Helikoptercrew Problem und Beispiel

Bilder von Raspy, Dashboard usw. machen und einfügen

Forschungsfragen Gewinnung von Nutzschall in komplexen Geräuschumgebungen

Welche Verfahren eignen sich, um aus einem akustisch überlagerten Gesamtsignal einen Nutzschall zu gewinnen, der für die Machine-Learning-basierte Zustandsbewertung besonders geeignet ist?

Unterfragen Welche in der Literatur beschriebenen Verfahren zur Behandlung, Reduktion oder Abgrenzung von Hintergrund- und Störgeräuschen erscheinen für den vorliegenden Anwendungskontext besonders geeignet?

Welche ausgewählten Verfahren lassen sich praktisch auf einem Edge Device umsetzen und hinsichtlich ihrer Eignung zur Gewinnung eines diagnostisch geeigneten Signals miteinander vergleichen?

Störgeräusche sind inkonsistent und impulshaft, Hintergrundgeräusche konstant - Atomisiert

- Ziel ist es das Signal zu finden, auf welchem die Anomalieerkennung maximal per-

formt (messbare Zielgröße). Dazu braucht es eine Vergleichslogik der getesteten Verfahren - Eine explizite Hypothese zum Trade-off zwischen Störunterdrückung und Erhalt diagnostisch relevanter Signalanteile formulieren (Spannungsraum zwischen Informationsverlust und Isolation)(Zu starke Denoising-Verfahren können Anomaliesignaturen unterdrücken)

Auch Hypothesen - eine vorläufige, wissenschaftliche Annahme über einen vermuteten Zusammenhang oder Sachverhalt.

- Hypothese : Wenn der Nutzschaall sauber extrahiert wird, wird die Zustandsüberwachung präziser

Angestrebter Nutzen: Hebel für die Anomalieerkennung - Hypothese : Wenn der Nutzschaall sauber extrahiert wird, wird die Zustandsüberwachung präziser

Systematischer Verfahrensvergleich - umfassend, belastbar kriteriengestützt

Trennung statt Verlust - Störschaallkontaminierte Abschnitte (z.B. Sprachanteile) werden nicht verworfen, sondern aufgetrennt, der Maschinenschaall bleibt erhalten und analysierbar

1.3 Gang der Arbeit

Top Down

Kapitel 2

Grundlagen

Schall - Alan Watts - ein Baum fällt im Wald - Schallwellen überlagern sich "Polyfonie"

Ein Gesamtsignal aus mehreren Teilsignalen ergibt sich durch deren Addition, sofern sich die beteiligten Größen gegenseitig nicht beeinflussen (**Moeser2015**).

Schwingungen = Vibrationen

Der Ton Sinuskurven als .wav-Dateien sind reine Töne (Sinustöne) die durch periodische Schwingungen definiert sind. Hz (Hertz) bedeutet Schwingungen pro Minute z.B. Kammerton A mit 440hz ist in der Musik der Stimmtton als gemeinsamer Bezugston mit dem alle Instrumente gleich gestimmt werden am Anfang eines klassischen Konzerts Die Tonhöhe (Frequenz) wird durch die Enge der Kurve beschrieben, während die Lautstärke (Amplitude) vom Ausschlag abhängt (Kurven von [https:// lehrklaenge.de](https://lehrklaenge.de))

Ein Ton der nur halb so hoch ist (rechte Seite) also eine Oktave tiefer hat eine doppelso lange Frequenz. Das akustische Signal Ein akustisches Schallsignal setzt sich aus ein komplexes Gemisch aus vielen Tönen mit unterschiedlichen Frequenzen und Pegelhöhen zusammensetzt. Dieses Signal ist analog und muss mit einem Analog/Digitalwandler digital repräsentiert werden um Sounddaten zu erzeugen Digitalisierung des analogen Signals zu Sounddaten (Variablen haben Einfluss auf Leistungsfähigkeit und Preis der



Abbildung 2.1: Enter Caption

Lösung) Die Abtastrate (Samplingrate) ist die Häufigkeit mit der das analoge Signal bei der Digitalisierung abgetastet wird. Je höher die Abtastrate umso mehr Messungen (Samples) werden erstellt. Die Bittiefe gibt den Dynamikumfang (Feine Abstufungen in der Lautstärke des Signals) des Signals an. Je höher die Bittiefe desto mehr Informationen werden pro Sample gespeichert. Je mehr samples und bittiefe umso mehr Daten müssen gespeichert und verarbeitet werden was anspruchsvoller wird und v.a. wenn es Echtzeitüberwachung sein soll.

sind schallwellen immer sinuswellen?

https://en.wikipedia.org/wiki/Computational_auditory_scene_analysis

Wieso Akustik und kein Schwingungsmonitoring? 1. Die Maschine kann noch Monate gut mit Schwingung weiterlaufen ohne das man vorzeitig Teile tauschen muss. Erst bei Geräuschen sollte man sinnvollerweise wechseln. Man verwendet die Teile natürlich-erweise schon mit gewisser Abnutzung muss sie aber nicht gleich ersetzen da Abrieb normal ist. 2. Es ist schwieriger Schwingungen zu detektieren als Schall zu detektieren. Man muss dazu nah an das Gerät und mitunter in dieses eingreifen um Sensorik zu verbauen. Schwingung zu messen ist nicht trivial und muss genau wissen an welchen Teilen man messen möchte. Das Geräusch ist einfacher und verlässlicher zu messen. Es sind keine Veränderungen an den Betriebsmitteln / Maschinen notwendig wie es nötig wäre bei der Anbindung von Schwingungssensoren. 3. Akustik sind Schwingungen die so laut werden, dass man sie akustisch wahrnehmen kann.

Mittels einer Fourier Transformation soll das komplexe digitalisierte akustische Signal zerlegt werden und zwar in die einzelnen Frequenzbereiche um dominierende Frequenzen zu identifizieren. Die Lautstärke / Amplitude wird dabei durch Farben visualisiert. Die Visualisierung erfolgt über ein Mel-Spektrogramm. Das ist ein Standardwerkzeug der Audio-KI. Bilderkennung statt Tonerkennung. Je heller desto lauter.

Spektrogramme sind anschaulicher als Sinuskurven

Z.B. hier klingt beim guten Teil die Frequenz um rund 1500Hz viel länger nach und bei 2 ist das Signal umso länger. Das menschliche Ohr hört das nicht aber der Algorithmus erkennt diesen Unterschied. Am besten wäre es bereits Fehlerklassen unterscheiden zu können. Veränderungen beginnen oft klein und schleichend oder treten nur kurz auf,



Abbildung 2.2: Enter Caption



Abbildung 2.3: Enter Caption



Abbildung 2.4: Enter Caption

dass kann ein menschlicher Isntandhalter nicht erkennen. z.B. Hier veranschaulicht die akustische Entwicklung eines Prüfstandes über Monate hinweg 48h Rückhören der akustischen Signale wird angeboten. In der Zeitachse kann man 48h zurückgehen. Die KI Daten werden ewig aufgehoben um so lang wie möglich zu lernen

-

Cocktail Party Problem - Auf einer Party reden viele Personen im gleichen Raum, zur selben Zeit. Ein Mikrophon nimmt das gemischte Signal auf, aber man möchte die Sprache einer einzelnen Person isolieren. - Die meisten Menschen haben die Fähigkeit sich auf ein Gespräch aus dem Gemisch zu fokussieren (Eigenschaft der Psychoakustik). Kann Software das auch ? - Aufgabe: individuelle Quellen aus einem gemischten Signal herauszulösen. - <https://direct.mit.edu/books/monograph/3887/Auditory-Scene-AnalysisThe-Perceptual-Organization> - <https://www.semanticscholar.org/paper/Modeling-human-sound-source-localization-and-the-Bodden/8284181d4a6ab447f70b3d5f0c29285acb02b5a8>

Frequenzanalyse - Fourier / FastFouriertransformation - <https://terhardt.userweb.mwn.de/>
- Hätte ich die Drehzahl würde viel mehr gehen - Tachometer / SPS / Konstante?
/ Schätzung? - Statst Anomalieerkennung auf Geräuschdaten Bilderkennung Ano-
alieerkennung mit z.B. CNN und Autoencoder o.A. auf den Spektrogrammbilderba-

sen - abr edge problem? Cloud OProblem weil die Insustrie keine Daten rausgeben möchte und alles offline sein soll - <https://sensemore.io/de/die-maschinendaten-verstehen/?srsltid=AfmBOoqEhLwbxjZIGUaOksjh4eNSdRg0fTw-IOe4xWptJKKDIQs2t0Fq> - Dein .wav-Signal ist eine Summe vieler Cosinus-Schwingungen unterschiedlicher Frequenzen. - Recherrche Moises App welche ML Modelle werden dabei genutzt - Stichwort Polyphonie aus dem Musikkontext

Signal-to-Noise-Ratio der eigentlichen Analyse steigt massiv. Ziel ist es das Signal so rein wie möglich zu machen / zu entrauschen

Instdhaltung - Wir nehmen ein additives Signalmodell an - Buzzword Echtzeitüberwachung - Industriekontext - Der Badewanneneffekt bei der Ausfallrate einer Maschine - Condition Monitoring - Smart Maintenance - Predictive Maintenance - Nicht erst bei einer Störung handeln, sondern bereits zuvor - Wie verläuft bisher klassische akustische Instandhaltung (Werkzeuge, Methoden usw.)? ggf. Interview mit dem Dude aus der Zeitung oder einem anderen - <https://www.idmt.fraunhofer.de/de/forschungsthemen/sound-field-control.html> - <https://www.elektronikpraxis.de/smarte-sensoren-fuer-condition-monitoring-a-703183/>

- Darüberhinaus ML Modell was bestimmt Fehler lernt z.B. Kupplungsschaden usw - also alle Noise aus Michaels Ordner

Nicht ungeplante Reparatur wenn die Maschine bereits ausfällt oder beschädigt ist sondern geplante Wartungen weil der Instandhalter weiß das sich ein Defekt andeutet (durch akustische Signale) Dadurch wird die Verfügbarkeit der Maschine erhöht und die Reparaturaufwände minimiert. Entweder weite Raumüberwachung oder mit einem externen Mikrofon sehr nah an ein zu überwachendes Teil hingehen

Eignung akustischer Signale zum Condition Monitoring:

Grafik von Schaeffler 2015 - „Schadensverlauf und Detektierbarkeit in Abhängigkeit der Zeit“ Literatur: In der Regel beginnt die Schädigungsphase dadurch das Partikel durch Reibung auftreten. Im nächsten Schritt beginnen dann leichte Schwingungen die noch nicht hörbar sind und erst wenn die Schädigungsphase fortgeschritten ist kommt es zu Geräuschen welche der Vorbote von Effekten wie Hitze und Rauch sind. Es handelt sich um eine zeitlich exponentielle Entwicklung. Wenn die Hitzeentwicklung beginnt ist es



Abbildung 2.5: Enter Caption

zu spät. Die Geräuschartwicklung ist noch gerade am Punkt des sinnvollen Eingriffs

Typische Störgeräusche die man ggf. schon vorklassifizieren könnte sind z.B. Schleifen also Reibung oder unerwünschte Kontakte z.B. durch einen stumpfen Drehmeißel, Rollenschleifen bei einem Förderband oder Schaufelräder bei einer Pumpe Schlaggeräusche also mechanische Impulse oder Lockerheit Unwuchten die auf periodische Auffälligkeiten hindeuten Lautstärke durch allgemeine Zunahme mechanischer Belastung in einer Maschine z.B. hier Werkzeugverschleiß bei einem Drehmeißel:

USP Why We? Why Now ? SIPREMA soll eine simple Lösung sein damit man nicht auf Verschleiß fährt aber auch nicht teure Lösungen einkaufen muss Von Rössel vorgerechnete ROIs Rössels Schädigungskurve Kurve zu frühzeitiger Erkennung von Maschinenschäden. Mit Geräusch, Hitze usw. Feststellung Optimaler Zeitpunkt für Ersatz / Eintritt der Schädigungsphase Durch den sogenannten Gewöhnungseffekt des Gehörs nehmen Instandhalter feine Veränderungen die sich über Tage einschleichen nicht wahr. Pumphausschen im Wald der Stadtwerke waren bisher komplett instandhaltungsmäßig unüberwacht Core kostet 2500Euro mit 3 Boxen und die Pro kostet 5000Euro mit 3 Boxen

Positionierung von SIPREMA: Kurve noch in der Literatur finden Frage ist der Aufwand Linke Seite der Kurve „Ich mache gar nix zum Thema Instandhaltung und tausche



Abbildung 2.6: Enter Caption



Abbildung 2.7: Enter Caption



Abbildung 2.8: Enter Caption

erst was aus, wenn es kaputt ist man fährt also komplett auf Verschleiß: dadurch sind die Kosten für Reparatur und Prozessausfälle empirisch und statistisch untersucht hoch Rechte Seite der Kurve „Auch sehr hohe Kosten da man sehr viel Geld für Predictive Maintenance ausgibt mit komplexen Softwareinstallationen, komplexen Sensoren und komplexen Algorithmen mit hohem Wartungsaufwand wie Pflegeaufwand - das ist angemessen für überaus wichtige Maschinen - aber für „normale Maschinen“ wären das viel zu hohe Kosten im Verhältnis zum Output der Maschine. SIPREMA liegt im Mittelpunkt „Optimumspunkt“ zwischen hohen Kosten und auf Verschleiß fahren mit Reparaturen und Stillstand. Badewanne:

Die Original Kurve kommt von Schubert und Strackeljan (1998: 201 - 318)“Schädigungskurve“

Die Überwachungsrelevanz der Anlage ergibt sich aus deren Preis x Achse und Prozessrelevanz Y Achse (Also wie eine Risikomatrix)

Bei Pro: Möglichkeit das KI System ganz gezielt auf die Anlagen und Systeme anzulernen Bei Core: Variante ohne manuelles Feedback durch „human in the loop“ aber trotzdem Anomaliewahrscheinlichkeitskommunikation Grauer Bereich: Auf Verschleiß fahren da sich maintenance nicht lohnt und das Gerät weder teuer noch Prozessrelevant ist - z.B. Aldi Ventilator in der Kantinenküche $V = \frac{MTBF}{MTBF + MTTR} \cdot 100$ Verfüg-



Abbildung 2.9: Enter Caption



Abbildung 2.10: Enter Caption



Abbildung 2.11: Enter Caption

barkeit der Maschine = $(\text{Mean Time between Failures also mittlere zeit zwischen zwei Ausfällen}) / (\text{MTBF} + \text{Mean Time to repair}) * 100$ Um die Verfügbarkeit zu erhöhen kann man entweder die MTBF erhöhen oder die MTTR reduzieren. SIPREMA setzt daran an den MTBF zu erhöhen Ein Beispiel (An einer Maschine mit sehr hohen Verfügbarkeit)

Fällt eine Maschine aus, dann entstehen oft hohe Prozesskosten da z.B. die ganze Produktion oder Logistik zum stehen kommen kann. Sehr guter ROI selbst wenn man nur die Prozesskosten betrachtet ohne Kosten für Reparatur und Ersatzteile zu betrachten. Eigentlich ein Nobrainer SIPREMA zu nutzen. Außerdem reduziert SIPREMA den Instandhaltungsaufwand. Die Instandhalter müssen nicht über das ganze Betriebsgelände laufen oder zu dezentralen entfernten Strukturen wie Pumphauschen fahren um diese abzuhören. Wenn dort eine SIPREMA Box steht kann er den Raum / die Maschine aus dem Home Office überwachen ohne das sogar aktiv tun zu müssen sondern lediglich auf einen Alarm der Box zu reagieren. Außerdem läuft die Überwachung damit 24/7 und nicht nur während eines Inspektionsrundgangs. Dadurch benötigt man auch weniger Instandhalter und die wo es tun haben einen besseren und Verlässlicheren Arbeitstag. Der Instandhalter lehrt bei der Pro Variante die KI indem er Feedback gibt. SIPREMA ist immer wach und immer da. Außerdem hat SIPREMA keine change blindness / Gewöhnungseffekt - kleine Veränderungen über lange Zeit hört ein Mensch nicht. Der Algorithmus schon Es empfiehlt sich in der Lernphase



Abbildung 2.12: Enter Caption

eine gut funktionierende Maschine zu nutzen. Bei Pro kann man auch aktiv schlechtergeräusche einer fehlerhaften Maschine aufnehmen und die KI auf dieses trainieren - Wissensdatenbank

Die Anomalien sind als Soundfile bis zu zwei Wochen hörbar Da menschliche Sprache gefiltert wird ist der Datenschutz sichergestellt Plug and Play Nach dem Start der SIPREMA BOX wird das Mikrofon automatisch aktiviert. Ein Software- assistent führt Schritt für Schritt durch den Prozess, nach 10 Minuten ist die BOX „ready“. Nach der Erstinbetriebnahme wird ein Datenstrom initiiert, der die Verarbeitung der digitalisierten akustischen Signale vornimmt. In der BOX befindet sich ein Server. Auf diesem werden die Daten abgespeichert und mithilfe diverser künstlicher Intelligenzmechanismen auf Anomalien untersucht. Alles erfolgt vollautomatisch Das Ergebnis der Anomalieerkennung wird Ihnen über ein übersichtliches Dashboard zur Verfügung gestellt. Dieses Dashboard ist einfach über die Eingabe einer entsprechenden URL in Ihrem Browser und eine Authentifikation erreichbar. Jede SIPREMA BOX hat ein eigenes Dashboard, in welchem die Ergebnisse der Überwachung sichtbar werden. Sie können am Dashboard: - den Status der Überwachung im Zeitverlauf anschauen - farblich codierte Anomalien im Zeitverlauf feststellen - die nativen Tonsignale, die zur Aufzeichnung der Anomalie führten, anhören - die detektierten Anomalien markieren („als Anomalie bestätigt“ oder „keine Anomalie“) - die bestätigten Anomalien bezeichnen

(bspw. mit dem konkreten Fehler, der festgestellt - wurde) - die Daten für weitere Schritte und Detektionen verwenden (Erläuterung folgt im Weiteren) - Remotehören Durch den Einsatz der KI lernt die SIPREMA BOX, je Einsatzort, die dort üblichen Geräusche, stellt anomale Geräusche fest und markiert diese. Das somit lernende System wird immer präziser und zeigt dann sehr deutlich an, wenn Anomalien festgestellt wurden Weniger Ausfälle = höhere Verfügbarkeit Die Daten von Stufe 2 wiederum können im dritten Schritt für eine Voraussage verwendet werden. So lässt sich voraussagen, wann entsprechende Ausfälle technischer Anlagen und Systeme zu erwarten sind. Die Reparatur erfolgt dadurch VOR einem Ausfall. Box + Lizenz Grundsätzlich stehen mehrere Möglichkeiten zur Netzwerkanbindung zur Verfügung. SIPREMA kann in bestehende LAN- oder WLAN-Strukturen eingebunden werden, sofern diese am Einsatzort verfügbar sind und genutzt werden sollen. In vielen Fällen ist dies jedoch mit Abstimmungen, Freigaben oder zusätzlicher Infrastruktur verbunden. Alternativ – und in der Praxis besonders einfach – kann SIPREMA über eine integrierte M2M-Mobilfunkanbindung betrieben werden. Dabei nutzt das System verfügbare Mobilfunknetze (GSM/LTE), um die Verbindung herzustellen. Die hierfür notwendigen Mobilfunkkosten sind bereits in der SIPREMA-Lösung enthalten. Separate Verträge, SIM- Management oder zusätzliche Abrechnungsschritte sind nicht erforderlich. Durch die M2M-Anbindung ist SIPREMA unabhängig von der lokalen IT-Infrastruktur und kann auch an Standorten eingesetzt werden, an denen kein LAN oder WLAN zur Verfügung steht. Voraussetzung ist lediglich, dass am Einsatzort grundsätzlich ein Mobilfunknetz empfangbar ist. Sollte die Funkverbindung an einem Standort eingeschränkt sein, kann SIPREMA optional mit einer externen Antenne betrieben werden. Dadurch lässt sich der Empfang gezielt verbessern und die Verbindungsstabilität erhöhen.

Core: Im Zeitverlauf lässt sich die Kritikalität der Anlage überwachen - Monitoringansicht wo man pro Stunde eine Aussage bekommt wie gut oder schlecht es der Anlage geht auf Basis eines antrainierten Schwellenwerts der beim Training erfasst wird. Wie beim Beispiel mit dem ansteigenden grünen Graphen. Anstieg an Anomalien= Verschlechterung Pro: Man sieht nicht nur das eine Anomalie vorhanden ist sondern kann diese auch manuell klassifizieren / ihr einen Namen geben und dieses Geräuschemuster somit der Box antrainieren. Die KI lernt wie bestimmte Fehlermuster klingen Slogan: Höre das was du nicht hörst



grafik13.png

Abbildung 2.13: Enter Caption



grafik14.png

Abbildung 2.14: Enter Caption



Abbildung 2.15: Enter Caption

Gibt es andere Anbieter ähnlicher Systeme ? Skizze anfertigen und hier echte Bilder der Box u.A. einbauen SIPREMA Pro ist die professionelle Variante der akustischen Zustandsüberwachung für anspruchsvolle Instandhaltungsumgebungen. Sie bietet alle Funktionen der automatischen Anomalieerkennung und erweitert diese um gezielte Lern-, Analyse- und Wissensfunktionen. SIPREMA Pro erkennt akustische Anomalien und ermöglicht es dem Anwender, diese aktiv zu qualifizieren. Anomalien können als relevant oder nicht relevant bewertet und mit Zustandsbeschreibungen verknüpft werden. Dieses qualifizierte Feedback fließt direkt in das Lernmodell ein und erhöht die Präzision der Erkennung über die Zeit. Alle Bewertungen werden in einer Wissensdatenbank gespeichert und sind nachvollziehbar, veränderbar und erweiterbar. Geräusche und Beschreibungen können später neu zugeordnet oder umklassifiziert werden. So entsteht ein standortspezifisches akustisches Wissenssystem, das unabhängig von einzelnen Personen nutzbar bleibt. Darüber hinaus erlaubt SIPREMA Pro das proaktive Anlernen von Geräuschen. Anwender können gezielt Soll- und Nicht-Soll-Geräusche aufnehmen und dem System bekannt machen. Dadurch lassen sich bekannte Fehlerbilder, besondere Betriebszustände oder kritische Geräusche gezielt trainieren. SIPREMA Pro bietet zusätzlich erweiterte Analyse- und Visualisierungsfunktionen, optionale Geräuschortung, Integrationsmöglichkeiten über Schnittstellen sowie projektspezifische Erweiterungen über Plugins. Damit eignet sich die Pro-Variante insbesondere für

komplexe Anlagen, wechselnde Betriebszustände und größere Instandhaltungsorganisationen. SIPREMA Pro eignet sich besonders für: • komplexe oder variable Anlagen • systematische, datenbasierte Instandhaltungsstrategien • Organisationen mit klaren Prozessen und Zuständigkeiten Hinweis: Wenn Sie eine rein statistische, wartungsarme Plug-and-Play-Lösung ohne manuelles Feedback bevorzugen, ist SIPREMA Core die passende Variante. Der Alarmierungsindex $AI(t)$ In der klassischen Zustandsüberwachung werden einzelne Auffälligkeiten oft detailliert interpretiert: Welches Geräusch ist das? Welche Ursache steckt dahinter? Ist es relevant oder harmlos? Dieser Ansatz ist fachlich richtig, setzt jedoch voraus, dass jede Abweichung einzeln bewertet wird. Der Alarmierungsindex von SIPREMA Core folgt einem anderen Prinzip. Er betrachtet nicht die einzelne Anomalie, sondern die Häufung von Anomalien über die Zeit. Denn in der Praxis zeigt sich: Verschlechtert sich der Zustand einer Anlage, nehmen insgesamt akustische Abweichungen vom Normalzustand zu – auch wenn einzelne Geräusche für sich genommen noch unspezifisch sind. Diese Entwicklung bildet der Alarmierungsindex mathematisch ab. Die zugrunde liegende Formel aggregiert Anomalien über ein definiertes Zeitfenster und verdichtet sie zu einem normierten Wert zwischen 0 und 100. Kurzfristige Zufallseinflüsse verlieren an Bedeutung, während systematische Veränderungen sichtbar werden. Entscheidend ist nicht das einzelne Ereignis, sondern das Muster im Zeitverlauf. Nach einer kurzen Lernphase – typischerweise sieben Tage – kennt SIPREMA Core das normale akustische Verhalten der Anlage. Auf dieser Basis schlägt das System automatisch einen Schwellenwert für die Alarmierung vor. Wird dieser überschritten, ist das ein belastbarer Hinweis auf eine Zustandsveränderung. Der Schwellenwert kann bei Bedarf angepasst werden – weitere Konfiguration ist nicht erforderlich. Die Stärke dieses Ansatzes liegt in seiner bewussten Reduktion. Da keine qualitative Bewertung einzelner Anomalien notwendig ist, entfällt der Aufwand für manuelles Feedback oder Training. Die Alarmierung basiert ausschließlich auf der statistischen Entwicklung des Anomalieaufkommens. So wird akustische Zustandsüberwachung wirklich Plug-and-Play – und relevante Veränderungen werden früh sichtbar.

Potentiale 1. Aufbau eines vortrainierten, boxübergreifenden Wissenssystems, welches den Nutzschall besser von Umgebungsgeräuschen trennt, typische Fremdgeräusche wie Schritte oder Türen automatisch ignoriert, konkrete Störungen für eine Maschi-



Abbildung 2.16: Enter Caption

nenklasse erkennt und klassifiziert (z.B. Membranbruch bei einer Pumpe oder Lager-schaden bei einer CNC) sowie Wissen aus früheren Ausfällen, ähnlichen Maschinen und anderen Boxen per Wissensdatenbank bzw. Transfer Learning für neue Kunden nutzbar macht. Denkbar wäre ein Datenabfluss von jeder Box auf einen zentralen Server wo diese Daten ausgewertet werden und neue Boxen die an ähnlichen Ma-schinen verwendet werden bereits tortrainiert geliefert werden (z.B. Edition Pumpe oder Edition CNC). Ein produktiver Alarm könnte einem Instandhalter dann auch gleich den vermuteten Schaden mitteilen 2. Datenverarbeitung und Analyse in einer zentralen Cloud anstatt auf einem Edge Device ? Das Edge Device könnte dadurch auf ein Mikrofon mit Energieversorgung und Konnektivität versimplifiziert werden. Außerdem könnte die zentralisierte Verarbeitung auf der von Röwaplan bereitgestellten Cloud bessere Möglichkeiten bieten, die Daten auch für das anlernen neuer Boxen zu nutzen. 3. Bessere Box aus Aluminium wie Apple Optik - Produktdesigner not-wendig. 4. Wie kann aus dem akustischen Gesamtsignal eines Maschinenraums ein robuster Merkmalsraum gewonnen werden, der den maschinenbezogenen Nutzschall gegenüber Hintergrund- und Störgeräuschen ausreichend isoliert, um eine zuverlässige Anomalieerkennung zu ermöglichen? Und welchen Beitrag können filterbasierte Ver-fahren wie der Wiener-Filter zur Reduktion von Hintergrund- und Störgeräuschen in der akustischen Zustandsüberwachung leisten? 5. Erweiterung zu einer multimodalen

Sensorfusionsbox mit z.B. optischer Überwachung, Schwingungssensor, Beschleunigungsaufnehmer, oder Maschinenstethoskop 6. Kann man Architekturbestandteile der Hardware und Software optimieren um den maximalen Informationsgehalt ohne exponentiell steigende Kosten zu erhalten (z.B. Frequenzbereich, Bittiefe, Abtastrate, ML Algorithmus, Statt Raspberry-Pis eine eigene Hardwarebasis aus Chips konstruieren um alle Architekturbestandteile zu optimieren 7. Benutzeroberfläche in Englisch, Französisch, Italienisch und Spanisch bereitstellen, aber nur wenn Kunden in diesen Ländern strategisch denkbar sind.

Daheim MVP machen: wenn man eine eigene Chip Architektur anstatt eines Raspys verwendet kann man sich viel Platz sparen und zusätzlich die Architektur auf den Zweck optimieren. Ein kleiner Gehäuse reicht (vlt. USB Größe) und kann deshalb aus Alu o.A. gefertigt werden

SIPREMA = Signalanalyse Plattform für Predictive Maintenance

Multi-channel BSS (ICA, SOBI, GEVD, MVDR) nutzt räumliche/statistische Unterschiede zwischen mehreren Kanälen → für dein Setup ausgeschlossen. Single-channel BSS (NMF, RPCA, VMD) trennt aus einer Beobachtung anhand struktureller Annahmen über die Quellen → genau dein Fokus.

Teil II

Literaturrecherche

Methodik

Die strukturierte Literaturrecherche orientiert sich am Framework von Webster u. a. (2002), das sich in der Wirtschaftsinformatik als methodischer Standard etabliert hat (Lehrstuhl für Digitales Management, Universität Hohenheim, 2025). Die verwendeten Quellen werden gemäß ISO 690 (Ernst & Sohn GmbH, 2023) zitiert.

Das methodische Vorgehen gliedert sich in vier Phasen. Zunächst wird über eine strukturierte Datenbanksuche der Stand der Forschung erhoben (Abschnitt 3.1 und 3.2). Die identifizierten Verfahren werden anschließend anhand von Eignungskriterien für den SIPREMA-Kontext bewertet (Abschnitt 3.3). Die als grundsätzlich geeignet eingestuften Verfahren werden prototypisch implementiert und an einem Referenzsignal erprobt. Auf Basis dieser Erprobung erfolgt die abschließende, begründete Auswahl der Verfahren für das Experiment.

3.1 Suchraum

Der Fokus der Recherche liegt auf Verfahren zur Signaltrennung und Rauschreduktion sowie auf Publikationen zur akustischen Zustandsüberwachung und Anomalieerkennung. Arbeiten ohne Bezug zur Signaltrennung oder Rauschreduktion werden ausgeschlossen. Ein Zeitraumfilter wird zunächst bewusst nicht gesetzt, um grundlegende Arbeiten der Signalverarbeitung einbeziehen zu können. Grundsätzlich werden Primärquellen bevorzugt.

3.2 Suchstrategie

Durchsucht werden die Datenbanken ACM Digital Library, Elsevier Scopus, IEEE Xplore, JSTOR, Springer Nature Link und Wiley Online Library. Die Suchanfragen kombinieren thematisch relevante Begriffe aus den Bereichen akustische Signalverarbeitung, Störgeräuschreduktion, Predictive Maintenance und Edge Computing. Die Suche erfolgt in englischer und deutscher Sprache. Die verwendeten Suchbegriffe sowie die erzielten Trefferzahlen sind in Anhang A.1 dokumentiert.

Die Auswahl relevanter Publikationen erfolgt mehrstufig. Zunächst werden die Titel der Treffer gesichtet und offensichtlich irrelevante Arbeiten ausgeschlossen; bei sehr hohen Trefferzahlen wird der Zeitraum eingeschränkt. Anschließend werden die Abstracts der verbleibenden Publikationen anhand des gesetzten Fokus bewertet. Für die danach verbleibenden Arbeiten wird der Volltext gesichtet.

Die Datenbanksuche wird durch zwei weitere Schritte ergänzt. Eine Rückwärtssuche prüft die Literaturverzeichnisse zentraler Arbeiten auf weitere relevante Quellen. Zusätzlich wird explorativ nach kommerziellen und nicht wissenschaftlich etablierten Ansätzen gesucht, die in den Datenbanken nicht erfasst sind.

3.3 Auswahlkriterien

Ziel der Auswahl ist nicht das fortschrittlichste Verfahren, sondern dasjenige, das im SIPREMA-Kontext optimal einsetzbar ist. Zunächst werden Kriterien definiert, die die Einsatzgrenzen im SIPREMA-Kontext abbilden. Anschließend werden die in der Literaturrecherche gefundenen Verfahren anhand dieser Kriterien bewertet. Das Ergebnis ist eine nachvollziehbare und begründete Auswahl für das Experiment. Die Kriterien wurden aus der technischen Architektur der SIPREMA-Hardware, dem Gespräch mit dem SIPREMA-Erfinder sowie dem in Kapitel 1.2 beschriebenen System hergeleitet.

K1 – Edge-Tauglichkeit SIPREMA ist ein Edge Device mit begrenzten Rechen- und Speicherressourcen. Verfahren, die eine GPU, große vortrainierte Modelle oder einen die verfügbare Hardware überlastenden Rechenaufwand erfordern, scheiden aus. Als

Orientierung dient die von Ko u. a. (2018) nachgewiesene Implementierung, die zeigt, dass Quelltrennung auf Edge-Niveau realisierbar ist. Verfahren mit vergleichbar geringem Aufwand gelten als Edge-tauglich.

K2 – Einzelkanalfähigkeit Die SIPREMA-Box enthält zwei MEMS-Mikrofone in derselben kompakten Gehäuseeinheit. Ihr räumlicher Abstand ist so gering, dass zwischen den Kanälen kein nutzbarer Laufzeitunterschied besteht; für Zwecke der Signaltrennung ist das System daher als Einzelkanal-System zu behandeln. Verfahren, die zwei oder mehr räumlich getrennte Mikrofone mit messbarem Laufzeitunterschied voraussetzen, sind nicht anwendbar. Darüber hinaus setzen mehrkanalige, BSS-basierte Verfahren statistische Unabhängigkeit der Quellsignale voraus – eine im SIPREMA-Szenario nicht verlässlich erfüllte Bedingung, da Maschinennutzschall und Fabrikhallenlärm gemeinsame Frequenzanteile aufweisen und durch den Hallraum korreliert sein können.

K3 – Keine Trainingsphase auf Störschall Im betrachteten Szenario ist der Störschall nicht vorab bekannt. Die akustische Umgebung einer Fabrikhalle wechselt: neue Maschinen kommen hinzu, Produktionsprozesse und Umwelteinflüsse ändern sich. Ein Verfahren, das eine repräsentative Stichprobe des Störschalls für Training oder Modellparametrisierung benötigt, ist im SIPREMA-Kontext nicht wartbar. Verfahren, die ohne gelabelte Trainingsdaten für den Störschall auskommen – also blinde oder unüberwachte Verfahren –, sind zu bevorzugen.

K4 – Physikalische Interpretierbarkeit Die Ausgabe des Trennverfahrens dient als Eingang für ein nachgelagertes ML-Modell zur Anomalieerkennung. Verzerrt das Trennverfahren das Maschinensignal systematisch oder führt es Artefakte ein, kann das Anomalieerkennungsmodell echte Anomalien nicht mehr von Trennungsartefakten unterscheiden. Verfahren, deren Ausgabe physikalisch interpretierbar ist und keine systematischen Verzerrungen des Nutzsignals einführt, sind daher zu bevorzugen.

Ein Verfahren wird nur dann als Experimentkandidat aufgenommen, wenn es die Kriterien K1 bis K4 erfüllt. Ergänzend werden die verbleibenden Kandidaten am Referenzsignal erprobt und über ein Kriterium der Zerlegungsgüte priorisiert (vgl. Abschnitt 4.2.2)."

Keine großen Änderungen aber: Suchstrings Cluster anpassen damit es zu den endgültigen Ergebnissen passt

Ergebnisse

4.1 Stand der Forschung

Die Datenbanksuche lieferte insgesamt 8.470 Treffer, von denen 72 anhand von Titel und Abstract genauer geprüft, 33 gespeichert und 20 als relevant priorisiert wurden. Die Rückwärtssuche ergab 121 weitere Referenzen, von denen 15 näher gesichtet, 12 gespeichert und 5 als relevant priorisiert wurden. Die genaue Verteilung ist in Anhang A.2 und A.3 dokumentiert.

Die identifizierten Verfahren lassen sich anhand ihres zugrunde liegenden Trennprinzips in Klassen gliedern. Maßgeblich ist dabei nicht die mathematische Herkunft eines Verfahrens, sondern die Frage, welche Eigenschaft des Signals es zur Unterscheidung von Nutz- und Störschall heranzieht. Die folgenden Abschnitte stellen die Klassen mit ihrer jeweiligen Trennlogik vor; die einzelnen Verfahren werden nur so weit ausgeführt, wie es zum Verständnis der Klasse nötig ist. Die vertiefte Darstellung der später ausgewählten Verfahren erfolgt in Abschnitt 4.3.

Physikalisch orientierte Verfahren Diese Klasse nutzt physikalische Eigenschaften des Maschinengeräuschs – Periodizität, Schwingung, Resonanz – zur Abgrenzung gegenüber dem Störschall. Die zugrunde liegende Trennlogik ist die Kopplung des Nutzschalls an die Maschinendrehzahl: Rotierende Komponenten erzeugen Signalanteile, die sich mit der Drehfrequenz f_r und ihren Harmonischen wiederholen, während Umgebungsgeräusche breitbandig und nicht an einen mechanischen Takt gebunden sind. Die **synchrone Mittelung** (McFadden1987) verstärkt den drehzahlsynchronen Anteil

durch Mittelung über die Rotationsperioden; **Bandpass- und Kammfilterung** (Randall, 2011) extrahieren gezielt die harmonischen Bänder; die **zyklostationäre Analyse** (Antoni, 2009) verallgemeinert dieses Prinzip auf Signale, deren statistische Eigenschaften periodisch mit der Drehzahl variieren, und erfasst so auch amplitudenmodulierte Anteile. Die Klasse ist durchgängig einzelkanalfähig, kommt ohne Trainingsphase aus und ist physikalisch direkt interpretierbar, setzt jedoch ausgeprägte periodische Signalmerkmale voraus.

Statistische Spektralschätzung Diese Klasse trennt über ein statistisch geschätztes Rauschmodell im Spektralbereich: Aus einem als störschalldominiert angenommenen Signalabschnitt wird das mittlere Rauschspektrum geschätzt und anschließend aus dem Gesamtsignal entfernt. Die **Spektralsubtraktion** (Boll, 1979) subtrahiert das geschätzte Rauschbetragsspektrum direkt; der **Wiener-Filter** (Wiener 1949) wendet stattdessen eine weiche, im quadratischen Mittel optimale Verstärkung an; der **MMSE-STSA-Schätzer** (Ephraim u. a., 1984) verfeinert diese weiche Dämpfung über eine statistisch optimale Amplitudenschätzung und reduziert dadurch Artefakte weiter. Alle drei Verfahren sind einzelkanalfähig und in ihrer Basisform ohne Trainingsphase betreibbar; sie setzen jedoch die Identifizierbarkeit eines rauschdominierten Referenzabschnitts voraus.

Struktur- und Faktorisierungsverfahren Diese Klasse trennt anhand struktureller Muster im Spektrogramm, ohne Drehzahlwissen. Die **Harmonic-Percussive Source Separation (HPSS)** (Fitzgerald, 2010; Driedger u. a., 2014) unterscheidet über Medianfilterung zwischen horizontal-stabilen (harmonischen) und vertikal-breitbandigen (perkussiven) Strukturen. Die **nichtnegative Matrixfaktorisierung (NMF)** (Lee u. a., 2000; Virtanen, 2007) zerlegt das Betragsspektrogramm in wiederkehrende spektrale Basismuster und deren zeitliche Aktivierungen. Die **robuste Hauptkomponentenanalyse (RPCA)** (Candès u. a., 2011) trennt eine niedrigrangige (repetitive) von einer spärlichen (sporadischen) Komponente. Allen dreien ist gemeinsam, dass die Zuordnung der zerlegten Anteile zu Nutz- oder Störschall nicht inhärent gegeben, sondern eine nachgelagerte Interpretation ist.

Adaptive Signal- und Modenzerlegung Diese Klasse zerlegt das Signal datengetrieben in schmalbandige Moden, deren Mittenfrequenzen sich adaptiv aus dem Signal selbst ergeben. Die **Empirical Mode Decomposition (EMD)** (Huang1998) zerlegt das Signal über ein iteratives Sifting-Verfahren in intrinsische Modenfunktionen; ihre Varianten EEMD und CEEMDAN mildern das Mode-Mixing durch Rauschzugabe. Die **Variational Mode Decomposition (VMD)** (Dragomiretskiy u. a., 2014) formuliert die Zerlegung stattdessen als Optimierungsproblem und ist dadurch robuster, erfordert aber die Vorgabe der Modenzahl. Die **Singular Spectrum Analysis (SSA)** zerlegt über eine Trajektorienmatrix nach zeitlicher Korrelationsstruktur. Die Zuordnung der Moden zu Nutz- oder Störschall erfolgt anhand ihres spektralen Schwerpunkts. Die Klasse ist einzelkanalfähig und trainingsfrei, die Zerlegungsqualität hängt jedoch von der Wahl der Modenzahl ab.

Psychoakustisch motivierte Verfahren Diese Klasse bildet die menschliche auditive Szenenanalyse nach: Über Gestaltgesetze der Wahrnehmung werden extrahierte Teiltöne zu akustischen Objekten gruppiert. Der Ansatz nach **Baumann1995** nutzt dazu Teiltonlinien und deren zeitliche Stabilität als Trennkriterium zwischen tonalen (maschinellen) und geräuschhaften Anteilen. Das Verfahren ist einzelkanalfähig, konzeptionell jedoch deutlich aufwendiger als die übrigen Klassen.

KI-basierte Verfahren Diese Klasse modelliert Trennung datengetrieben über tiefe neuronale Netze. Foundation-Modelle wie **SAM Audio** (Meta AI, 2025) und **AudioSep** (Liu u. a., 2023) erlauben eine flexible Steuerung über Text- oder visuelle Prompts und erreichen hohe Trennqualität, erfordern jedoch GPU-Ressourcen, große vortrainierte Modelle und ein Training auf umfangreichen Datensätzen. Spezialisierte Echtzeitsysteme (Krisp Technologies, 2025; NVIDIA Corporation, 2025; Adobe Inc., 2025) sind ausschließlich auf Sprache trainiert und nicht auf Maschinengeräusche übertragbar.

4.1.1 Nicht anwendbare Verfahrensklassen

Zwei in der Literatur prominente Klassen sind im SIPREMA-Kontext konstruktionsbedingt nicht anwendbar und werden daher nicht als Kandidaten geführt.

Die **mehrkanalige blinde Quelltrennung (BSS)** – darunter GEVD-basierte Verfah-

ren (Parra u. a., 2003; Yeredor, 2011), SOBI (Belouchrani u. a., 1997), zeitverzögerte Kreuzkorrelation (Molgedey u. a., 1994), MVDR-Beamforming (Schwartz u. a., 2017) sowie das Adaptive Noise Cancelling (Widrow u. a., 1975) – setzt mindestens zwei räumlich getrennte Mikrofone mit messbarem Laufzeitunterschied voraus. Da die SIPREMA-Hardware zwei MEMS-Mikrofone in einem kompakten Gehäuse ohne verwertbare räumliche Diversität verbaut, ist das System für Zwecke der Signaltrennung als Einzelkanal-System zu behandeln; die gesamte Klasse entfällt damit über Kriterium K2. Ergänzend setzen BSS-Verfahren statistische Unabhängigkeit der Quellen voraus, die im SIPREMA-Szenario durch gemeinsame Frequenzanteile und Raumhall nicht verlässlich erfüllt ist.

Eigene, auf Störschall trainierte Deep-Learning-Ansätze entfallen über Kriterium K3: Der Störschall ist im Zielszenario nicht vorab bekannt und ändert sich mit der Produktionsumgebung, sodass eine repräsentative Trainingsstichprobe nicht wartbar bereitgestellt werden kann. Vortrainierte Foundation-Modelle bleiben davon unberührt und werden im Experiment als externe Referenz geführt (Abschnitt 4.2).

Zusammenfassend zeigt der Stand der Forschung eine klare Lücke: Einzelkanalfähige Verfahren zur Gewinnung von Nutzschaall aus Maschinengeräuschen unter realen Industriebedingungen und auf ressourcenbeschränkter Hardware sind bislang nicht systematisch untersucht. Bestehende Systeme setzen entweder mehrere Mikrofone, leistungsfähige Hardware oder domänenspezifische Trainingsdaten voraus. An dieser Lücke setzt die vorliegende Arbeit an.

4.2 Begründete Auswahl

Die vollständige Bewertung aller identifizierten Verfahren anhand der Kriterien K1 bis K4 ist in Anhang A.4 dokumentiert. Nach Anwendung der Kriterien verbleiben Kandidaten aus fünf Verfahrensklassen, die alle Anforderungen erfüllen: die statistische Spektralschätzung, die physikalisch orientierten Verfahren, die Struktur- und Faktorisierungsverfahren, die adaptive Modenzerlegung sowie das psychoakustisch motivierte Verfahren. Für die vertiefte Implementierung wird aus vier dieser Klassen jeweils mindestens ein Verfahren übernommen; die psychoakustische Klasse wird

zwar erprobt, aus den in Abschnitt 4.2.2 genannten Gründen jedoch nicht weiterverfolgt. Die nachfolgenden Absätze fassen die Ausschlüsse zusammen und bestimmen anschließend je Klasse das für die vertiefte Implementierung ausgewählte Verfahren.

4.2.1 Ausschlüsse nach den Auswahlkriterien

Ausschluss durch mangelnde Edge-Tauglichkeit (K1) Das NMF-Verfahren mit Wigner-Verteilung nach Omlor u. a. (2011) überschreitet durch seinen Rechenaufwand die Ressourcen des SIPREMA-Edge-Devices und scheidet über K1 aus. Die Deep-Learning- und Foundation-Model-Ansätze – SAM Audio (Meta AI, 2025), AudioSep (Liu u. a., 2023), der Denoising Autoencoder (Torun u. a., 2025) sowie Density Network Denoising (Schmitt u. a., 2024) – setzen GPU-Ressourcen oder große vortrainierte Modelle voraus und scheiden als reguläre Kandidaten ebenfalls über K1 aus. Bei mehreren dieser Verfahren ist der Ausschluss durch weitere Kriterien zusätzlich begründet.

Ausschluss durch fehlende Einzelkanalfähigkeit (K2) Sämtliche BSS- und GEVD-basierten Verfahren – GEVD-BSS (Parra u. a., 2003), das lineare BSS-Framework (Li, 2022), SOBI (Belouchrani u. a., 1997), zeitverzögerte Kreuzkorrelation (Molgedey u. a., 1994), die Performanzanalyse nach Yeredor (2011), MVDR in Kombination mit einem Wiener-Filter (Schwartz u. a., 2017) sowie das Adaptive Noise Cancelling (Widrow u. a., 1975) – setzen mindestens zwei räumlich getrennte Mikrofone mit messbarem Laufzeitunterschied voraus. Da die SIPREMA-Hardware diesen konstruktionsbedingt nicht bereitstellt, scheidet die gesamte Klasse über K2 aus.

Ausschluss durch erforderliche Trainingsphase (K3) Das State-Space-Verfahren mit EM-Schätzung nach Olsson u. a. (2006) setzt eine Trainingsphase voraus und scheidet über K3 aus. Der Kalman-Filter nach Wu u. a. (2018) wird ebenfalls nicht als vollständiger Kandidat übernommen, da seine Rauschschätzung eine stabile Störcharakteristik voraussetzt, die bei wechselnden Umgebungsgeräuschen nicht garantiert ist. Die bereits über K1 ausgeschlossenen Deep-Learning-Ansätze erfüllen K3 aufgrund ihres Trainings auf großen gelabelten Datensätzen ebenfalls nicht.

4.2.2 Bestimmung des Klassensiegers

Innerhalb jeder verbleibenden Klasse wurde zunächst mehr als ein Verfahren prototypisch implementiert und am Referenzsignal `observ_1.wav` erprobt. Da für ein reales Feldsignal kein Referenzsignal (Ground Truth) vorliegt, das die exakte Zerlegung in Nutz- und Störschall vorgibt, sind klassische Trennmetriken wie SDR oder SNR am Referenzfile nicht anwendbar. Die Vorauswahl erfolgt daher über ein objektives, referenzfreies Kriterium der **Zerlegungsgüte**, das ausschließlich die beiden Ausgangssignale $\hat{s}_{Ns}$ (Nutzschall) und $\hat{s}_{Hs}$ (Störschall) eines Verfahrens bewertet.

Ein Verfahren trennt umso besser, je vollständiger es das Eingangssignal erhält und je stärker sich seine beiden Ausgänge inhaltlich unterscheiden. Daraus ergeben sich zwei Messgrößen. Der **Rekonstruktionsfehler** misst, wie vollständig die Summe beider Ausgänge das Eingangssignal y wiederherstellt:

$$\varepsilon_{\text{rek}} = \frac{y - (\hat{s}_{Ns} + \hat{s}_{Hs})_2}{y_2} \quad (4.1)$$

Ein kleiner Wert bedeutet, dass weder Signalenergie verloren geht noch Artefakte hinzugefügt werden. Die **Komplementarität** misst über den Betrag des Korrelationskoeffizienten, wie stark sich die beiden Ausgänge inhaltlich überlappen:

$$\rho = \left| \frac{\langle \hat{s}_{Ns}, \hat{s}_{Hs} \rangle}{\hat{s}_{Ns2} \hat{s}_{Hs2}} \right| \quad (4.2)$$

Ein kleiner Wert von ρ bedeutet, dass Nutz- und Störschall weitgehend unterschiedliche Signalanteile enthalten, die Trennung also trennscharf ist. Als Klassensieger wird dasjenige Verfahren ausgewählt, das bei erhaltener Rekonstruktion ($\varepsilon_{\text{rek}} \leq 0,05$) die niedrigste Überlappung ρ erreicht.

Dieses Kriterium ist bewusst einfach gehalten. Es bewertet nicht, ob die Zuordnung von Nutz- und Störschall inhaltlich korrekt ist, sondern nur, ob das Verfahren am Referenzsignal überhaupt eine saubere, trennscharfe Zerlegung liefert. Es dient damit ausschließlich der *Vorauswahl* eines repräsentativen Verfahrens je Klasse. Die belastbare Bewertung der Trennqualität erfolgt im nachgelagerten Experiment (Kapitel ??) auf einem umfangreichen Datensatz mit kontrollierten Bedingungen.

Tabelle 4.1 zeigt die am Referenzsignal gemessene Zerlegungsgüte aller erprobten Verfahren. Innerhalb jeder Klasse ist das Verfahren mit der niedrigsten Überlappung ρ bei eingehaltener Rekonstruktion hervorgehoben.

Tabelle 4.1: Zerlegungsgüte je Verfahren am Referenzsignal `observ_1.wav`. ε_{rek} : Rekonstruktionsfehler, ρ : Komplementarität (Betrag der Korrelation zwischen Nutz- und Störschall). Kleinere Werte sind besser. Fett: niedrigstes ρ je Klasse bei eingehaltener Rekonstruktion.

Klasse	Verfahren	ε_{rek}	ρ
4*Physikalisch	Synchrone Mittelung	0,0010	0,0000
	Bandpass-/Kammfilter	0,0002	0,4708
	Cepstrum	0,0002	0,6636
	Zyklostationäre Analyse	0,0002	0,6972
3*Statistisch (Spektral)	Wiener	0,0002	0,1513
	MMSE-STSA	0,0002	0,2424
	Spektralsubtraktion	0,0002	0,3242
3*Struktur/Faktorisierung	NMF	0,0002	0,3381
	HPSS	0,0002	0,4626
	RPCA	0,0002	0,5520
6*Modenzerlegung	EMD	0,0086	0,0207
	Matching Pursuit	0,0107	0,0224
	CEEMDAN	0,0066	0,0295
	SSA	0,0002	0,1624
	VMD	0,1001	0,0085*
	EEMD	0,1076	0,0935*
Psychoakustisch	Wahrnehmungsbasiert (Baumann)	0,0002	0,1034

* Rekonstruktion verletzt ($\varepsilon_{\text{rek}} > 0,05$); trotz niedrigem ρ nicht als Sieger gewählt, da wesentliche Signalenergie verloren geht.

Das Kriterium bestimmt für jede Klasse einen eindeutigen Sieger. In der physikalischen Klasse trennt die synchrone Mittelung die beiden Anteile vollständig entkoppelt ($\rho = 0,000$), was die strukturelle Trennung von drehzahlsynchronem und asynchronem Anteil widerspiegelt. In der statistischen Spektralschätzung erreicht der Wiener-Filter die niedrigste Überlappung ($\rho = 0,151$), in der Struktur- und Faktorisierungsklasse die NMF ($\rho = 0,338$). In der adaptiven Modenzerlegung greift die Rekonstruktions-Nebenbedingung: VMD weist zwar das niedrigste ρ auf, verliert jedoch rund ein Zehntel der Signalenergie ($\varepsilon_{\text{rek}} = 0,10$) und wird daher nicht gewählt; Sieger ist EMD.

Das psychoakustische Verfahren nach **Baumann1995** erreicht am Referenzsignal ebenfalls eine trennscharfe Zerlegung ($\rho = 0,103$), wird jedoch nicht für das Experiment übernommen: Sein Implementierungs- und Rechenaufwand liegt deutlich über dem der übrigen Kandidaten, und die zugrunde liegenden perzeptiven Modellgrößen sind ursprünglich für die Trennung polyphoner Musik konzipiert und nur eingeschränkt auf Maschinengeräusche übertragbar. Die Klasse wird daher im Stand der Forschung geführt, aber nicht vertieft implementiert.

4.2.3 Ausgewählte Verfahren

Über den jeweiligen Klassensieger hinaus werden in zwei Klassen ergänzend Verfahren übernommen, die sich am Referenzsignal komplementär verhalten und im Experiment unterschiedliche Stärken auf breiter Datenbasis zeigen sollen. In der statistischen Spektralschätzung werden neben dem Sieger Wiener auch die Spektralsubtraktion und MMSE-STSA weiterverfolgt, da sie sich in der Art der spektralen Dämpfung – harte Subtraktion, weiche optimale Verstärkung bzw. statistisch verfeinerte Amplitudenschätzung – unterscheiden. In der Struktur- und Faktorisierungsklasse werden neben dem Sieger NMF auch HPSS und RPCA übernommen, da sie unterschiedliche Signalanteile isolieren: HPSS die perkussiven Anteile über die strukturelle Anisotropie, NMF die stationären Maschinenkomponenten über die spektrale Basiszerlegung und RPCA die transienten Ereignisse über die niedrigrangig/spärliche Trennung. In den übrigen Klassen genügt jeweils der Klassensieger. Diese Mehrfachauswahl ist bewusst gewählt, da die belastbare Bewertung der Trennqualität erst im nachgelagerten Experiment erfolgt.

Tabelle 4.2 fasst die ausgewählten Verfahren zusammen.

Tabelle 4.2: Für die vertiefte Implementierung ausgewählte Verfahren je Klasse. Der Klassensieger nach dem Zerlegungskriterium (Abschnitt 4.2.2) ist mit $\star$ gekennzeichnet; ergänzend übernommene, komplementär trennende Verfahren ohne Markierung.

Klasse	Ausgewähltes Verfahren	Hauptquelle
Physikalisch orientiert	Synchrone Mittelung $\star$	McFadden1987
Statistische Spektralschätzung	Wiener-Filter $\star$	Wiener1949
Statistische Spektralschätzung	Spektralsubtraktion	Boll (1979)
Statistische Spektralschätzung	MMSE-STSA	Ephraim u. a. (1984)
Struktur/Faktorisierung	NMF $\star$	Virtanen (2007)
Struktur/Faktorisierung	HPSS	Fitzgerald (2010)
Struktur/Faktorisierung	RPCA	Candès u. a. (2011)
Adaptive Modenzerlegung	EMD $\star$	Huang1998
KI-Referenz (gesetzt)	SAM Audio	Meta AI (2025)

Die KI-basierte Klasse wird nicht über das Zerlegungskriterium ausgewählt, sondern durch **SAM Audio** als externe Referenz repräsentiert. Die Begründung liegt in der Aktualität des Modells und der breiten Forschungsbasis hinter promptgesteuerten Foundation-Modellen zur Audioquellentrennung. SAM Audio tritt im Experiment nicht als K1–K4-konformer Kandidat an, sondern als obere Vergleichsmarke, an der sich die klassischen Verfahren messen lassen. Analog wird für die kommerziellen Stem-Splitter-Applikationen ein aktueller Vertreter als Referenz geführt; seine Auswahl folgt derselben Begründung über Aktualität und Verbreitung. Liu u. a. (2023) konnte im abgeschotteten Zielumfeld nicht in Betrieb genommen werden und wird ausschließlich als Beleg für die Deployment-Hürden datengetriebener Verfahren angeführt (Kapitel ??).

4.3 Implementierung

In diesem Abschnitt werden die in Abschnitt 4.2 ausgewählten Verfahren vertieft dargestellt. Für jedes Verfahren werden das zugrunde liegende Signalmodell, die zur Trennung von Nutz- und Störschall verwendete Logik sowie die konkrete Umsetzung in Python beschrieben. Die Darstellung folgt der Klassengliederung aus dem Stand der Forschung. Das vollständige Notebook ist in Anhang A.5 dokumentiert; die

Codeausschnitte im Text beschränken sich auf die für das Verständnis wesentlichen Schritte.

Alle Verfahren verarbeiten dasselbe Referenzsignal `observ_1.wav` (einkanalig) und erzeugen jeweils zwei Ausgangssignale: den geschätzten Nutzschaall (N_S) und den geschätzten Stör- bzw. Hintergrundschaall (H_S). Sofern nicht anders angegeben, wird für Verfahren im Frequenzbereich eine STFT mit einer Fensterlänge von 1024 Abtastwerten und einer Überlappung von 512 Abtastwerten verwendet.

4.3.1 Physikalisch orientierte Verfahren

Synchrone Mittelung

Die synchrone Mittelung wurde von **McFadden1987** als Modell zur Extraktion periodischer Wellenformen durch Mittelung im Zeitbereich eingeführt und ist auch als *Time Domain Averaging* bekannt. Das Verfahren nutzt die Drehzahlkopplung des Nutzschaalls direkt aus: Ein periodisches Teilsignal mit bekannter Wiederholrate lässt sich vom additiven Rauschen trennen, indem das Signal in Perioden zerlegt und über diese gemittelt wird.

Die Grundannahme ist ein additives Signalmodell. Das Gesamtsignal $y(t)$ setzt sich aus einem periodischen Teilsignal $x(t)$ mit bekannter Wiederholrate T_r und einem Rauschanteil $e(t)$ zusammen:

$$y(t) = x(t) + e(t) \quad (4.3)$$

Ist die Wiederholfrequenz bekannt, kann das repetitive Signal vom Rauschen getrennt werden. **McFadden1987** nennt als Anwendung explizit die Zustandsüberwachung rotierender Maschinen mit bekannter Drehzahl.

Periodenlänge. Die Drehzahl wird als Variable `rpm` (Umdrehungen pro Minute) geführt; sie kann aus technischer Dokumentation, über eine Tacho- oder OPC-UA-Schnittstelle oder durch Autokorrelation aus dem Signal geschätzt werden. Die Länge einer Periode P in Abtastwerten ergibt sich aus der Abtastrate A (Variable `sr`) und der Drehzahl:

$$P = \frac{A}{\text{rpm}/60} \quad (4.4)$$

Die Division durch 60 überführt die Drehzahl von Umdrehungen pro Minute in Umdrehungen pro Sekunde, konsistent zur Abtastrate. Über eine ganzzahlige Division wird die Anzahl vollständiger Perioden M bestimmt; die letzte, unvollständige Periode wird verworfen:

$$M = \left\lfloor \frac{N}{P} \right\rfloor \quad (4.5)$$

mit N als Gesamtzahl der Abtastwerte.

[language=Python] periode = int(sr / (rpm / 60)) anzahl_{perioden} = len(y) // periode

Segmentierung und Mittelung. Das Signal wird in M gleich lange Perioden zerlegt und in einer Segmentmatrix $S \in \mathbb{R}^{M \times P}$ abgelegt, deren Zeilen die einzelnen Umdrehungen und deren Spalten die Abtastwerte innerhalb einer Periode enthalten:

$$S = (y)_0[0] \cdots y_0[P-1] : \cdots : y_{M-1}[0] \cdots y_{M-1}[P-1] \quad (4.6)$$

Der Mittelwert über alle Zeilen ergibt die gemittelte Periode. Das periodische Maschinensignal steht in jeder Umdrehung an derselben Position und bleibt daher erhalten, während das zufällige Rauschen sich beim Mitteln zunehmend aufhebt:

$$\bar{p}[k] = \frac{1}{M} \sum_{i=0}^{M-1} S_{i,k} \quad (4.7)$$

Die Unterdrückung des Rauschens skaliert mit $1/\sqrt{M}$; je mehr Umdrehungen einbezogen werden, desto besser die Trennung. Der Nutzsoll entsteht durch Kachelung der gemittelten Periode über die volle Signallänge, der Störsoll als Differenz zum Original:

[language=Python] segmente = np.array([y[i*periode:(i+1)*periode] for i in range(anzahl_{perioden})])
 np.tile(segmente.mean(axis = 0), anzahl_{perioden})
 stoerschall_sm = y[: len(nutzsoll_sm)] -
 nutzsoll_sm

Die synchrone Mittelung ist das konzeptionell direkteste Verfahren zur Nutzung der physikalischen Eigenschaften rotierender Maschinen und besitzt damit die höchste Passung zum Signalmodell dieser Arbeit. Ihre zentrale Voraussetzung ist eine genau bekannte Drehzahl: Geht A/f_r nicht ganzzahlig auf, akkumuliert sich über viele Perioden ein Rundungsfehler, und der synchrone Anteil verschmiert. Für konstante, glatt teilbare Drehzahlen ist das Verfahren robust; für stark schwankende Drehzahlen wäre eine

winkelsynchrone Abtastung (Order Tracking) erforderlich, die hier nicht implementiert wird.

4.3.2 Statistische Spektralschätzung

Spektralsubtraktion

Die Spektralsubtraktion wurde von Boll (1979) an der University of Utah im Rahmen eines DARPA-geförderten Projekts zur Rauschunterdrückung in Sprachsignalen entwickelt und ist bis heute eine der Standardmethoden der klassischen Störschallreduktion. Das Verfahren geht von einem additiven Rauschmodell aus. Das gemessene Signal $y(t)$ setzt sich aus dem Nutzsignal $s(t)$ und einer additiven Störung $n(t)$ zusammen; nach STFT gilt im Frequenzbereich entsprechend:

$$Y(f) = S(f) + N(f) \quad (4.8)$$

Die zentrale Annahme ist, dass aus einem Referenzabschnitt ohne Nutzsignal eine Schätzung des mittleren Rauschbetragsspektrums $\mu(f)$ vorliegt. Das Nutzsignal wird geschätzt, indem dieses Rauschbetragsspektrum vom Betragsspektrum des Gesamtsignals subtrahiert wird, während die Phase des Gesamtsignals erhalten bleibt:

$$|\hat{S}(f)| = |Y(f)| - \mu(f), \quad \arg \hat{S}(f) = \arg Y(f) \quad (4.9)$$

Da die Subtraktion negative Beträge erzeugen kann, werden diese durch Halbwellen-Gleichrichtung auf null gesetzt:

$$|\hat{S}(f)| = \max(|Y(f)| - \mu(f), 0) \quad (4.10)$$

Der geschätzte Störschall ergibt sich als Differenz zum ursprünglichen Spektrum, $\hat{N}(f) = Y(f) - \hat{S}(f)$. Beide Anteile werden anschließend per inverser STFT und Overlap-Add in den Zeitbereich zurücktransformiert.

Referenzabschnitt im SIPREMA-Kontext. Das ursprüngliche Verfahren nutzt Sprachpausen zur Rauschschätzung. Für rotierende Maschinen fehlt ein solches Kriterium für nutzschallfreie Abschnitte. In dieser Arbeit wird der Referenzabschnitt daher durch eine dedizierte Referenzaufnahme bei stillstehender Maschine gewonnen: Unmittelbar

vor der Messung wird bei identischer Mikrofonposition und unveränderter akustischer Umgebung ein kurzer Abschnitt aufgezeichnet, der ausschließlich Stör- und Hintergrundschall enthält. Aus diesem Abschnitt wird das mittlere Rauschbetragsspektrum $\mu(f)$ geschätzt und auf das Beobachtungssignal angewendet. Die Spektralsubtraktion ist das recheneffizienteste Verfahren dieser Klasse und dient im Experiment als untere Vergleichsreferenz.

Wiener-Filter

Der Wiener-Filter geht auf **Wiener1949** zurück und ist die im quadratischen Mittel (MSE) optimale lineare Schätzung eines Nutzsignals aus einer additiv gestörten Beobachtung. Angewendet im Kurzzeit-Spektralbereich sitzt er konzeptionell zwischen der harten Subtraktion der Spektralsubtraktion (Abschnitt 4.3.2) und dem statistisch verfeinerten MMSE-STSA-Schätzer (Abschnitt 4.3.2): Statt das Rauschspektrum hart abzuziehen, wird pro Frequenzbin eine weiche Verstärkung angewendet, die vom lokalen Signal-Rausch-Verhältnis abhängt. Am Referenzsignal erzielt der Wiener-Filter die trennschärfste Zerlegung der Klasse (Abschnitt 4.2.2).

Ausgehend vom additiven Modell $Y(k, n) = S(k, n) + N(k, n)$ und einer Schätzung der Störschallleistung $\lambda_d(k)$ ergibt sich die Wiener-Verstärkung aus dem a-priori-Signal-Rausch-Verhältnis $\xi_k(n)$:

$$G_k(n) = \frac{\xi_k(n)}{1 + \xi_k(n)}, \quad \xi_k(n) = \frac{\lambda_s(k, n)}{\lambda_d(k)} \quad (4.11)$$

Wo das Nutzsignal dominiert ($\xi_k \gg 1$), nähert sich die Verstärkung eins und der Bin wird nahezu unverändert durchgelassen; wo der Störschall dominiert ($\xi_k \ll 1$), geht die Verstärkung gegen null und der Bin wird gedämpft. Der geschätzte Nutzschall folgt durch Anwendung der Verstärkung auf das komplexe Spektrogramm, der Störschall als komplementärer Anteil:

$$\hat{S}(k, n) = G_k(n) Y(k, n), \quad \hat{N}(k, n) = (1 - G_k(n)) Y(k, n) \quad (4.12)$$

Im Vergleich zur Spektralsubtraktion erzeugt die weiche Verstärkung deutlich weniger „Musical Noise“, ohne den Rechenaufwand des Bessel-basierten MMSE-STSA-Schätzers zu erfordern. Der Wiener-Filter teilt mit den übrigen Verfahren dieser Klasse die Voraus-

setzung einer Schätzung der Störschalleistung $\lambda_d(k)$ aus einem als störschalldominiert angenommenen Signalabschnitt (Abschnitt 4.3.2).

Minimum Mean-Square Error Short-Time Spectral Amplitude (MMSE-STSA)

Das MMSE-STSA-Verfahren wurde von Ephraim u. a. (1984) am *Technion – Israel Institute of Technology* entwickelt und entstammt ebenfalls der Sprachverstärkung in additiv gestörten Signalen. Im Gegensatz zur harten Subtraktion der Spektralsubtraktion (Abschnitt 4.3.2) folgt MMSE-STSA einem statistischen Modellierungsansatz: Die DFT-Koeffizienten von Nutz- und Störschall werden als statistisch unabhängige, komplexe, mittelwertfreie Gauß-Zufallsvariablen angenommen. Statt hart zu subtrahieren, wird pro Frequenzbin eine weiche, statistisch optimale Verstärkung angewendet, was das für die Spektralsubtraktion typische „Musical Noise“ reduziert.

Für ein gestörtes Signal $Y(k, n) = X(k, n) + D(k, n)$ im Frequenzbin k und Zeitrahmen n definieren Ephraim u. a. (1984) das a-posteriori- und das a-priori-Signal-Rausch-Verhältnis:

$$\gamma_k(n) = \frac{|Y(k, n)|^2}{\lambda_d(k)}, \quad \xi_k(n) = \frac{\lambda_x(k, n)}{\lambda_d(k)} \quad (4.13)$$

mit $\lambda_d(k)$ als Varianz des Störschalls und $\lambda_x(k, n)$ als Varianz des Nutzschalls. Da λ_x nicht direkt beobachtbar ist, wird $\xi_k(n)$ rekursiv über die *decision-directed*-Schätzung gewonnen:

$$\xi_k(n) = \alpha \cdot \frac{\hat{A}_k^2(n-1)}{\lambda_d(k)} + (1 - \alpha) \cdot \max(\gamma_k(n) - 1, 0) \quad (4.14)$$

mit einem Glättungsfaktor $\alpha \approx 0,98$, der die Schätzung über aufeinanderfolgende Rahmen stabilisiert. Der MMSE-Schätzer der Spektralamplitude lautet:

$$G_k(n) = \frac{\sqrt{\pi}}{2} \cdot \frac{\sqrt{\nu_k(n)}}{\gamma_k(n)} \cdot \left[(1 + \nu_k(n)) I_0(\nu_k(n)2) + \nu_k(n) I_1(\nu_k(n)2) \right] e^{-\nu_k(n)/2} \quad (4.15)$$

mit $\nu_k(n) = \frac{\xi_k(n)}{1 + \xi_k(n)} \gamma_k(n)$ sowie I_0 und I_1 als modifizierten Bessel-Funktionen erster Art nullter bzw. erster Ordnung. Die geschätzte Nutzschallamplitude ergibt sich als $\hat{A}_k(n) = G_k(n) \cdot |Y(k, n)|$; die Phase wird unverändert aus dem gestörten Signal übernommen, da die MMSE-Schätzung der Phase unter der Gauß-Annahme mit der beobachteten Phase zusammenfällt:

$$\hat{X}(k, n) = G_k(n) \cdot |Y(k, n)| \cdot e^{j\angle Y(k, n)} \quad (4.16)$$

Wie die übrigen Verfahren dieser Klasse erfordert MMSE-STSA eine Schätzung der Störschallvarianz $\lambda_d(k)$ aus dem störschalldominierten Referenzabschnitt (Abschnitt 4.3.2).

4.3.3 Struktur- und Faktorisierungsverfahren

Harmonic-Percussive Source Separation (HPSS)

Die Harmonic-Percussive Source Separation trennt ein Signal anhand der strukturellen Anisotropie seines Magnitudenspektrogramms. **Ono2008** zeigten an der University of Tokyo, dass harmonische und perkussive Klangkomponenten in einem STFT-Spektrogramm $|X(k, n)|$ (Frequenzindex k , Zeitindex n) unterschiedlich erscheinen: Harmonische Komponenten bilden horizontale Grate, die über mehrere Zeitrahmen bei konstanter Frequenz stabil bleiben, perkussive Komponenten dagegen vertikale, breitbandige Grate. Fitzgerald (2010) nutzte diese Anisotropie für ein einfaches, schnelles Trennverfahren auf Basis von Medianfilterung, das ohne iterative Optimierung auskommt.

Die Medianfilterung entlang der Zeitachse verstärkt harmonische Strukturen, da sie perkussive Impulse unterdrückt:

$$\tilde{Y}_h(k, n) = \text{median}\{|X(k, n - L_h)|, \dots, |X(k, n + L_h)|\} \quad (4.17)$$

Analog verstärkt die Medianfilterung entlang der Frequenzachse perkussive Strukturen:

$$\tilde{Y}_p(k, n) = \text{median}\{|X(k - L_p, n)|, \dots, |X(k + L_p, n)|\} \quad (4.18)$$

L_h und L_p sind die Filterlängen entlang Zeit- bzw. Frequenzachse und die zentralen Hyperparameter. Aus $\tilde{Y}_h$ und $\tilde{Y}_p$ werden weiche Masken abgeleitet (Driedger u. a., 2014):

$$M_h(k, n) = \frac{\tilde{Y}_h(k, n)^p}{\tilde{Y}_h(k, n)^p + \tilde{Y}_p(k, n)^p}, \quad M_p(k, n) = 1 - M_h(k, n) \quad (4.19)$$

mit einem Schärfeparameter p . Die Trennung erfolgt durch Anwendung der Masken auf das komplexe Spektrogramm und anschließende inverse STFT:

$$\hat{X}_h(k, n) = M_h(k, n) \cdot X(k, n), \quad \hat{X}_p(k, n) = M_p(k, n) \cdot X(k, n) \quad (4.20)$$

HPSS benötigt im Gegensatz zur synchronen Mittelung (Abschnitt 4.3.1) keine Drehzahlinformation, sondern ausschließlich die Zeit-Frequenz-Struktur des Signals. Wel-

cher der beiden Anteile dem Nutzschall entspricht, ist nicht a priori festgelegt, sondern experimentell zu prüfen.

Non-negative Matrix Factorization (NMF)

NMF wurde von **LeeSeung1999** an den Bell Laboratories als allgemeines Zerlegungsverfahren für nichtnegative Daten eingeführt und von **LeeSeung2001** um multiplikative Updateregeln ergänzt. **SmaragdisBrown2003** übertrugen das Verfahren erstmals auf Audiosignale, um polyphone Musik anhand wiederkehrender Notenspektren zu zerlegen – ein Vorgehen, das sich unmittelbar auf die Zerlegung von Maschinenschall in wiederkehrende Spektralmuster übertragen lässt. Am Referenzsignal erreicht NMF die trennschärfste Zerlegung ihrer Klasse (Abschnitt 4.2.2).

Grundidee ist die Approximation eines nichtnegativen Magnitudenspektrogramms $V \in R_{\geq 0}^{F \times N}$ durch das Produkt zweier nichtnegativer Matrizen:

$$V \approx WH, \quad W \in R_{\geq 0}^{F \times K}, \quad H \in R_{\geq 0}^{K \times N} \quad (4.21)$$

W enthält K spektrale Basisvektoren (charakteristische Frequenzmuster), H die zugehörigen zeitlichen Aktivierungen. Die Faktorisierung wird durch Minimierung der generalisierten Kullback-Leibler-Divergenz bestimmt:

$$D_{\text{KL}}(V \parallel WH) = \sum_{f,n} \left(V_{fn} \log \frac{V_{fn}}{(WH)_{fn}} - V_{fn} + (WH)_{fn} \right) \quad (4.22)$$

Die Minimierung erfolgt iterativ über die multiplikativen Updateregeln nach **LeeSeung2001**:

$$H \leftarrow H \odot \frac{W^T (V \oslash WH)}{W^T \mathbf{1}}, \quad W \leftarrow W \odot \frac{(V \oslash WH) H^T}{\mathbf{1} H^T} \quad (4.23)$$

mit $\odot$ und $\oslash$ als elementweiser Multiplikation bzw. Division.

Zuordnung über den spektralen Schwerpunkt. NMF liefert keine inhärente Zuordnung der K Basisvektoren zu Nutz- oder Störschall. Eine Zuordnung über die Nähe zur Drehfrequenz und deren Harmonischen ($|\omega - n f_r| \leq f_r/2$) ist bei kleiner Drehfrequenz f_r unbrauchbar, da dann nahezu jede Frequenz in die Nähe eines Vielfachen von f_r fällt. Stattdessen wird der spektrale Schwerpunkt (Centroid) jeder Komponente herangezogen: Komponenten mit Schwerpunkt im Maschinenband ($\leq f_{\text{grenze}}$, hier $f_{\text{grenze}} = 800$ Hz) werden dem Nutzschall zugeordnet, höherfrequente dem Störschall.

Der Centroid ist robuster als die Harmonik-Nähe-Prüfung und wird konsistent auch bei der Modenzerlegung (Abschnitt 4.3.4) verwendet. [language=Python] `nutzschallnmf = np.zeros(len(y))`
`stoerschallnmf = np.zeros(len(y))`
`forkinrange(K) : komponente = W[:, [k]]@H[[k], :]`
`Teilspektrogrammcentroid = (freqs*komponente.sum(axis = 1)).sum()/komponente.sum()`
`istftkkomponente(komponente, phase)`
`if centroid <= fgrenze : nutzschallnmf += signalk`
`else : stoerschallnmf += signalk`

Robust Principal Component Analysis (RPCA)

RPCA in Form der *Principal Component Pursuit* wurde von Candès u. a. (2011) entwickelt. Ausgangspunkt ist die Annahme, dass sich eine Datenmatrix M als Summe einer niedrigrangigen Matrix L und einer spärlich besetzten Matrix S darstellen lässt: $M = L + S$. Im Gegensatz zu NMF (Abschnitt 4.3.3) wird keine Basiszerlegung gelernt, sondern eine strukturelle Trennung nach Rang und Sparsität erzwungen. Candès u. a. (2011) zeigen, dass sich L und S unter milden Bedingungen durch folgendes konvexe Optimierungsproblem rekonstruieren lassen:

$$\min_{L, S} \|L\|_* + \lambda \|S\|_1 \quad \text{u. d. N.} \quad L + S = M \quad (4.24)$$

mit der Nuklearnorm $\|L\|_*$ als konvexer Surrogat für den Matrixrang, der ℓ_1 -Norm $\|S\|_1$ als konvexem Surrogat für Sparsität und dem Gewichtungsfaktor $\lambda = 1/\sqrt{\max(F, N)}$. Zur Lösung wird die Methode der augmentierten Lagrange-Multiplikatoren (ALM) nach **Lin2010** verwendet, die iterativ den Singulärwert-Schwellenwertoperator $\mathcal{D}_\tau$ und den Weichschwellenwertoperator $\mathcal{S}_\tau$ anwendet: $L_{k+1} = \mathcal{D}_{\mu_k^{-1}}(M - S_k + \mu_k^{-1}Y_k)$
 $S_{k+1} = \mathcal{S}_{\lambda\mu_k^{-1}}(M - L_{k+1} + \mu_k^{-1}Y_k)$
 $Y_{k+1} = Y_k + \mu_k(M - L_{k+1} - S_{k+1})$ wobei $\mathcal{D}_\tau(X) = U \mathcal{S}_\tau(\Sigma) V^\top$ mit $X = U \Sigma V^\top$ und $\mathcal{S}_\tau(x) = \text{sign}(x) \max(|x| - \tau, 0)$ elementweise. Y_k ist der Lagrange-Multiplikator, μ_k ein wachsender Strafparameter.

Angewendet auf ein Magnitudenspektrogramm $M = |X(k, n)|$ entspricht die niedrigrangige Komponente L Strukturen, die sich über viele Zeitrahmen wiederholen – ein Kriterium, das auf periodische Maschinensignale (Nutzschall) zutrifft, da deren Zeit-Frequenz-Struktur über mehrere Rotationsperioden stabil bleibt. Die spärliche Komponente S erfasst zeitlich lokalisierte, nicht wiederkehrende Ereignisse, was impulsivem Störschall entspricht. Wie bei HPSS und NMF ist diese Zuordnung eine

Interpretation der Verfahrensstruktur und experimentell zu verifizieren.

4.3.4 Adaptive Modenzerlegung

Empirical Mode Decomposition (EMD)

Die Empirical Mode Decomposition wurde von **Huang1998** eingeführt und zerlegt ein Signal rein datengetrieben in eine endliche Zahl intrinsischer Modenfunktionen (Intrinsic Mode Functions, IMF) – ohne vorgegebene Basis und ohne Frequenzannahme. Am Referenzsignal liefert EMD die trennschärfste Zerlegung ihrer Klasse bei eingehaltener Rekonstruktion (Abschnitt 4.2.2).

Sifting. Kern des Verfahrens ist der iterative Sifting-Prozess. Für ein Signal werden die lokalen Maxima und Minima bestimmt und durch Interpolation zu einer oberen und unteren Hüllkurve verbunden. Von ihrem Mittelwert $m(t)$ wird das Signal befreit; der verbleibende Anteil $h(t) = x(t) - m(t)$ wird so lange wiederholt gesiftet, bis er die IMF-Bedingung erfüllt (Anzahl der Extrema und Nulldurchgänge unterscheidet sich höchstens um eins, und die Hüllkurven sind symmetrisch). Die so gewonnene IMF wird vom Signal abgezogen und das Verfahren auf den Rest angewendet. Frühe IMFs enthalten die schnellsten Oszillationen, spätere zunehmend langsamere. Die Varianten EEMD und CEEMDAN mildern das sogenannte Mode-Mixing durch mehrfache Zerlegung mit zugefügtem Rauschen, erhöhen dabei jedoch den Rechenaufwand deutlich.

Zuordnung. Die Zuordnung der IMFs zu Nutz- und Störschall erfolgt – konsistent mit NMF (Abschnitt 4.3.3) – über den spektralen Schwerpunkt: IMFs im Maschinenband ($\leq f_{\text{grenze}}$) bilden den Nutzsoll, die übrigen den Störschall. [language=Python] from PyEMD import EMD imfs = EMD().emd(y)

```
nutzschallemd = np.zeros(len(y))
stoerschallemd = np.zeros(len(y))
for imf in imfs :
    if centroidhz(imf, sr) <= fgrenze : nutzschallemd += imf
    else : stoerschallemd += imf
```

Abgrenzung zur Variational Mode Decomposition. Als variational formulierte Alternative zu EMD wurde ergänzend die *Variational Mode Decomposition* (VMD) (Dra-

gomiretskiy u. a., 2014) erprobt. VMD löst die Zerlegung nicht heuristisch, sondern als Optimierungsproblem: Minimiert wird die Summe der Modenbandbreiten unter der Rekonstruktions-Nebenbedingung $\sum_{k=1}^K u_k = f$, gelöst per Alternating Direction Method of Multipliers im Frequenzbereich. VMD ist gegenüber EMD robuster gegen Mode-Mixing, erfordert jedoch die Vorgabe der Modenzahl K und erwies sich am Referenzsignal als weniger geeignet: Bei der niedrigen Grundfrequenz des Signals gelang die Isolation der tiefen Maschinenkomponente nur unvollständig, sodass die Rekonstruktions-Nebenbedingung verletzt wurde (Abschnitt 4.2.2). Für die vertiefte Weiterverfolgung wurde daher EMD gewählt.

Die Implementierung aller Verfahren in Python ist vollständig in Anhang A.5 dokumentiert.

Teil III

Experiment

Methodik

Das Ziel des Experiments ist es, die in Kapitel ?? identifizierten Trennverfahren unter kontrollierten und reproduzierbaren Bedingungen zu prüfen.

Dazu wird ein Ventilator als Nutzschaallquelle im Normalzustand und mit gezielt herbeigeführten Anomalien aufgezeichnet, ebenso einige Stör- und Hintergrundgeräusche. Darauf basierend wird ein Mischsignal konstruiert, wobei für jedes Teilsignal das reine Signal als Referenz bekannt ist (Ground Truth). Bewertet wird anschließend nicht die Trennqualität selbst, sondern die Leistung bei der Anomalieerkennung.

5.1 Aufbau

Der Aufbau wurde im Freifeldraum der Hochschule Aalen durchgeführt. Dessen schallabsorbierende Beschaffenheit unterdrückt Reflexionen nahezu vollständig. Zugleich ist der Raum gegen Außenlärm abgeschirmt. Durch optische Markierungen im Raum und am Untersuchungsobjekt konnten konsistente Positionen über alle Messungen sichergestellt werden. Die Ausrichtung von Mikrofon und Quelle sowie die Mikrofonkonfiguration wurde ebenfalls konstant gehalten. Somit existierten gleiche Bedingungen über das gesamte Experiment hinweg und alle Einzelaufnahmen entstanden unter identischen Bedingungen.

Als **Nutzschaallquelle** dient ein handelsüblicher Ventilator. Dieser erzeugt ein Geräuschemuster, wie es für rotierende Maschinen typisch ist. Zudem lassen sich Fehlerzustände gezielt herbeiführen und zurücknehmen, und der Aufbau ist mit geringem Aufwand reproduzierbar. Alle Aufnahmen erfolgen bei mittlerer Drehzahlstufe.

Die **Anomaliezustände** werden so gewählt, dass sie typische Fehlerzustände rotierender Maschinen abbilden (cite - Auswahl mit Röwaplan abgestimmt).

1. **Tonal:** Verstärkung vorhandener Frequenzen oder Auftreten neuer Töne, etwa bei einer Unwucht. Am Ventilator wird dazu ein Zusatzgewicht auf einem Rotorblatt angebracht.
2. **Impulshaft:** Einzelne kurze Stöße, etwa bei einem Wälzlagerschaden oder einer losen Verbindung. Am Ventilator wird dazu die Rotorschraube gelockert.
3. **Breitbandig:** Anhaltendes Rauschen, etwa bei Anstreifen oder Mangelschmierung. Am Ventilator wird dazu am Gehäuse ein Klebeband angebracht, das die Rotorblätter streift.

Jeder Zustand wird in zwei Schweregraden aufgenommen.

Tabelle 5.1: Herbeigeführte Anomaliezustände

Zustand	Umsetzung	Stufen
A1 Unwucht	Zusatzgewicht auf einem Rotorblatt	0,5 g / 1 g
A2 Lose Befestigung	definiertes Lösen der Rotorschraube	leicht / deutlich
A3 Anstreifen	Klebeband am Gehäuse, das die Rotorblätter streift	leicht / deutlich

Die **Stör- und Hintergrundgeräusche** werden, wenn möglich im Messraum erzeugt oder dem ESC-50 Datensatz entnommen (cite ESC 50 (**Piczak2015**)).

Unterschieden wird zwischen *Störgeräuschen*, die kurz und einmalig auftreten, und *Hintergrundgeräuschen*, die dauerhaft und gleichbleibend vorhanden sind.

Die **Messkette** umfasst ein Freifeldmikrofon Brüel & Kjær Typ 4190, das der Präzisionsklasse WS 2 F nach IEC 61094-4 und damit der höchsten Genauigkeitsklasse (1) entspricht (**IEC61672**). Aufgezeichnet wird mit einer Abtastrate von 44,1 kHz und einer Auflösung von 24 bit im unkomprimierten WAV-Format.

Tabelle 5.2: Stör- und Hintergrundgeräusche

Quelle	Erzeugung
<i>Störgeräusche</i>	
S1 Schläge	Zuschlagen einer Kiste
S2 Werkzeug	Hammerschläge auf Metallplatte
S3 Gespräch	drei Personen
S4 Ak- kuschrauber	kurzer Betrieb
S5 Tierlaute	ESC-50
S6 Alarm	ESC-50
S7 Hupe	ESC-50
<i>Hintergrundgeräusche</i>	
H1 Verkehr	Außenaufnahme mit Smartphone
H2 Ak- kuschrauber	konstanter Betrieb
H3 Ak- kuschrauber	dynamischer Betrieb

Alle Teilsignale wurden isoliert aufgezeichnet, die Mischung erfolgte anschließend rechnerisch. Dadurch ist die Ground Truth für jedes Teilsignal vorliegend, im Sinne des in Kapitel ?? eingeführten additiven Signalmodells.

5.1.1 Versuchsplan und Pegelstufen

Die Faktoren des Versuchs werden kombiniert (**Montgomery2013**). So lässt sich erkennen, ob ein Trennverfahren generell gut abschneidet oder nur bei bestimmten Störgeräuschen.

Die Pegelverhältnisse werden nachträglich eingestellt, für Stör- und Hintergrundschall jeweils in den Stufen +10, 0 und −10 dB. Die Störereignisse werden zusätzlich in unterschiedlicher Häufigkeit an zufällig gewählten Zeitpunkten eingesetzt.

Die Auswertung erfolgt auf Abschnitten von fünf Sekunden Länge, wie bei SIPRE-MA. Daraus ergeben sich die Aufnahmedauern: Der Normalzustand wird 20 Minuten aufgezeichnet, da aus ihm die Trainingsdaten des Anomaliedetektors stammen, was 240 Abschnitten entspricht. Die Anomaliezustände sowie die Hintergrundgeräusche werden jeweils drei Minuten aufgezeichnet, was 36 Abschnitten entspricht. Bei den ereignishaften Störgeräuschen ist nicht die Dauer maßgeblich, sondern die Zahl der Ereignisse; je Quelle werden 15 Einzelereignisse aufgezeichnet, sodass für jede Mischung ein anderes Exemplar verwendet werden kann.

Tabelle 5.3: Aufnahmeliste für die Labormessung

Block	Anzahl	Inhalt
Nutzschall, Normalzustand	1	mittlere Drehzahlstufe
Nutzschall, Anomaliezustand	3	A1–A3
Störgeräusche	7	S1–S7, Maschine abgeschaltet
Hintergrundgeräusche	3	H1–H3, Maschine abgeschaltet
Grundgeräusch des Raums	1	alle Quellen abgeschaltet
Summe	15	

5.1.2 Verarbeitungskette nach SIPREMA-Vorbild

Die Verarbeitung bildet die Kette des SIPREMA-Systems nach und ergänzt sie um die Trennstufe.

Vorverarbeitung. Zunächst werden alle Rohaufnahmen einmalig von 48 auf 16 kHz dezimiert, mit vorgeschaltetem Tiefpass (`scipy.signal.decimate`, Faktor 3, `ftype='fir'`). Die 48-kHz-Fassung bleibt unangetastet. Aus den Einzelaufnahmen werden anschließend die Testfälle erzeugt: Nutzsignal plus skaliertes Störschall plus skaliertes Hintergrundschall, wobei die Skalierung über das Leistungsverhältnis nach den definierten SNR-Stufen erfolgt und Störereignisse an zufälligen, über einen festgehaltenen Seed reproduzierbaren Zeitpunkten eingesetzt werden.

Trennung. Jedes der untersuchten Verfahren wird auf das Mischsignal angewandt; Ergebnis ist je Verfahren das geschätzte Nutzsignal. Dieses wird in Blöcke von fünf Sekunden segmentiert, was den Übergabepunkt an die Merkmalsberechnung bildet.

Merkmalsberechnung. Aus jedem Segment wird ein Merkmalsvektor aus zeit- und frequenzbasierten Größen gebildet:

Anomalieerkennung. Die Erkennung erfolgt unüberwacht, ausschließlich auf Normaldaten trainiert. SIPREMA verwendet einen Isolation Forest (Liu2008) als ressourcenschonende Alternative zum autoencoderbasierten Rekonstruktionsfehler der DCASE-Baseline. Vor dem Training werden die Merkmale skaliert, da sie stark verschiedene Größenordnungen aufweisen und ohne Skalierung die großen Werte die Trennschnitte dominieren; der Skalierer wird auf den Trainingsdaten gefittet und auf die Testdaten angewandt.

Das Trainingsprotokoll ist dabei wesentlich: Für jedes Trennverfahren wird ein eigenes Modell auf den Normaldaten trainiert, die mit demselben Verfahren getrennt wurden. Würde stattdessen ein Modell auf sauberen Daten trainiert und auf getrennten Daten getestet, erschienen die Trennartefakte selbst als Anomalie, und gemessen würde der Unterschied zwischen Trainings- und Testbedingung statt der Eignung des Verfahrens.

Tabelle 5.4: Merkmale des SIPREMA-Merkmalsvektors

Merkmals	Berechnung
<i>Zeitbasiert</i>	
Mittelwert	<code>np.mean</code>
Minimum	<code>np.min</code>
Maximum	<code>np.max</code>
Standardabweichung	<code>np.std</code>
RMS	<code>np.sqrt(np.mean(seg**2))</code>
Anzahl Peaks	<code>scipy.signal.find_peaks</code>
<i>Frequenzbasiert</i>	
Frequenzbandenergien	Summe des Leistungsspektrums je Band
Spektraler Zentroid	<code>librosa.feature.spectral_centroid</code>
Spektrale Bandbreite	<code>librosa.feature.spectral_bandwidth</code>
Mel-Spektrogramm	<code>librosa.feature.melspectrogram</code>
MFCC	<code>librosa.feature.mfcc</code>

5.2 Bewertung

Mischung und Verfahrensanwendung erfolgen auf einer nachträglich auf 16 kHz dezierten Fassung, um mit der aktuellen Konfiguration von SIPREMA übereinzustimmen.

5.2.1 Zielgröße

Die Bewertung richtet sich nicht danach, wie sauber ein Verfahren trennt, sondern danach, wie gut die Anomalieerkennung auf dem getrennten Signal arbeitet. Diese Festlegung ist notwendig, weil beides auseinanderfallen kann: Ein Trennverfahren kann die Signalqualität messbar verbessern und die Anomalieerkennung gleichzeitig verschlechtern.

Der Grund liegt in der Natur der Anomalieinformation. Beginnende Schäden äußern sich häufig in leisen, breitbandigen oder kurzen Signalanteilen. Ein Trennverfahren, das auf Energie oder Hörbarkeit optimiert ist, entfernt genau diese Anteile als vermeint-

liche Störung. Es kann also Störenergie beseitigen und dabei die zustandsrelevante Information mit entfernen.

Maße der Trennqualität werden daher weiterhin erhoben, dienen aber als Zwischengröße. Über die Eignung eines Verfahrens entscheidet die Erkennungsleistung.

5.2.2 Bewertungskette

Als Referenz dient die Verarbeitungskette des SIPREMA-Systems. Sie besteht aus drei Stufen: der Zerlegung des Signals in Segmente von fünf Sekunden, der Berechnung eines Merkmalsvektors aus zeit- und frequenzbasierten Größen sowie der Anomalieerkennung mit einem Isolation Forest (**Liu2008**). Der Isolation Forest lernt unüberwacht aus Normaldaten und bewertet anschließend, wie stark ein Segment davon abweicht.

Die Kette wird unverändert übernommen. Die Trennung wird vor der Merkmalsberechnung eingefügt; für jedes Verfahren entsteht dadurch eine eigene Fassung des Signals, auf der die restliche Kette unverändert arbeitet.

5.2.3 Vergleichsbedingungen

Jedes Verfahren wird gegen zwei Referenzen verglichen.

Tabelle 5.5: Bedingungen des Verfahrensvergleichs

Bedingung	Eingangssignal	Bedeutung
Baseline	Mischsignal, ungetrennt	aktueller Stand des Systems
Treatment	getrenntes Signal je Verfahren	die zu prüfende Größe
Oracle	reines Nutzsignal	obere Schranke des Erreichbaren

Die Baseline zeigt, was ohne Trennung erreichbar ist; der Gewinn eines Verfahrens ist die Differenz zu diesem Wert. Das Oracle ist notwendig, um diesen Gewinn einordnen zu können: Es zeigt, wie gut die Erkennung bei vollständig entferntem Stör- und Hintergrundschall arbeiten würde. Ohne diese Schranke bleibt offen, ob eine Verbesserung um wenige Prozentpunkte nahe am Machbaren liegt oder weit davon entfernt. Zugleich dient das Oracle als Kontrolle für die übrige Kette: Erkennt der Detektor eine

Anomalie bereits auf dem sauberen Signal schlecht, liegt die Ursache bei Merkmalen oder Detektor und nicht beim Trennverfahren.

5.2.4 Metriken

Als Hauptmaß dient die Fläche unter der Grenzwertoptimierungskurve (AUC). Sie ist unabhängig von der gewählten Entscheidungsschwelle und daher für einen Verfahrensvergleich geeignet. Ergänzend wird die partielle AUC im Bereich niedriger Falschalarmrate berichtet; dieser Bereich ist für den industriellen Einsatz maßgeblich, da ein System mit häufigen Fehlalarmen in der Praxis abgeschaltet wird.

Ein Verfahren gilt nur dann als geeignet, wenn es die Erkennungsleistung gegenüber der Baseline nicht verschlechtert.

Als Nebengrößen werden Maße der Trennqualität erhoben: das skaleninvariante Signal-Störabstands-Verhältnis (**LeRoux2019**) sowie die Zerlegung in Interferenz-, Rausch- und Artefaktanteile (**Vincent2006**). Zusätzlich werden der Rekonstruktionsfehler und die Komplementarität aus der vorangegangenen Untersuchungsphase mitgeführt. Damit lässt sich prüfen, wie gut diese ohne Referenzsignal berechenbaren Kennzahlen mit den Maßen übereinstimmen, die ein Referenzsignal voraussetzen.

Der Vergleich beider Ebenen ist ein eigenständiges Ergebnis: Fällt die Übereinstimmung zwischen Trennqualität und Erkennungsleistung gering aus, bestätigt dies die eingangs formulierte These.

5.2.5 Eignung für den Edge-Betrieb

SIPREMA arbeitet auf einem Gerät mit begrenzten Ressourcen. Ein Verfahren, das die Erkennungsleistung verbessert, aber die verfügbare Rechenzeit überschreitet, ist nicht einsetzbar. Erfasst werden daher für jedes Verfahren die Rechenzeit je Segment und der Speicherbedarf. Beide Größen werden als Nebenbedingung geführt und nicht mit der Erkennungsleistung verrechnet.

5.2.6 Absicherung der Ergebnisse

Der Isolation Forest enthält Zufallsanteile. Jede Auswertung wird daher fünfmal mit unterschiedlichen Startwerten wiederholt; berichtet werden Mittelwert und Streuung. Ohne diese Angabe lässt sich nicht beurteilen, ob ein Unterschied zwischen zwei Verfahren auf deren Eigenschaften oder auf Zufall beruht. Alle Startwerte der Mischung und des Trainings werden festgehalten, sodass sich jedes Ergebnis reproduzieren lässt.

5.2.7 Erwartungen

Aus den Trennprinzipien der untersuchten Verfahren lassen sich Erwartungen ableiten, die im Ergebnisteil zu prüfen sind. Sie sind so formuliert, dass sie widerlegt werden können.

- H1** Statistische Verfahren setzen voraus, dass sich die Störung über die Zeit kaum ändert. Sie sollten daher beim Hintergrundschall gut abschneiden und bei kurzen Störereignissen versagen.
- H2** Zerlegende Verfahren trennen über strukturelle Unterschiede. Sie sollten kurze Störereignisse besser bewältigen als die statistischen Verfahren.
- H3** Die synchrone Mittelung nutzt die Periodizität des Maschinengeräuschs. Sie sollte gegen beide Störarten robust sein, jedoch die impulshafte Anomalie beschädigen, da diese nicht streng periodisch auftritt.
- H4** Kein Verfahren erhält alle drei Anomaliearten gleich gut. Die Eignung ist von der Art des Fehlerzustands abhängig.

Diese Auswahl macht prüfbar, ob ein Trennverfahren einen Fehlerzustand fälschlich als Stör- oder Hintergrundschall entfernt. Ein Verfahren, das einen deutlich ausgeprägten Fehler erhält, einen beginnenden jedoch entfernt, wäre für die Zustandsüberwachung im praxisrelevanten Frühstadium wenig geeignet.

Auch Test von Varianten und Kombinationen von Verfahren - welche sind sinnvoll ?
z.B. RPCA + NMF oder RPCA + Wiener ?

- [] Auswahl begründen für Referenzmodelle (Diffusionsmodell: SamAudio, StemSplitter: lalal.ai als voicecleaner NN)

Ergebnisse

Das Ergebnis ist ein Datensatz mit isolierten Geräuschmustern, die sich zu einem Mischsignal kombinieren lassen, bei dem alle Einzelsignale bekannt sind. Diese Referenz erlaubt als *Ground Truth* eine objektive Beurteilung der Trennleistung. Ziel ist der Erhalt zustandsrelevanter Information nach der Signaltrennung, um damit eine robustere Anomalieerkennung zu ermöglichen.

6.1 $\mathbf{x}$

6.2 $\mathbf{y}$

Teil IV

Diskussion

Kapitel 7

Interpretation

Bewertung der Forschungsfragen / Hypothesen

Einordnung

8.1 Erkenntnisgewinn

Schlussfolgerung

8.2 Limitationen

Der Einsatz eines Referenzmikrofons anstelle der SIPREMA-Hardware ist bewusst gewählt, da diese nicht dauerhaft festgelegt ist.

Würde man die Quellen gleichzeitig im Raum wiedergeben, vermischten sie sich akustisch, und für die Einzelquellen läge kein reines Referenzsignal vor.

Der beschriebene Aufbau erkauft die Verfügbarkeit eines Ground Truth mit einer Reihe von Einschränkungen, die bei der Interpretation der Ergebnisse zu berücksichtigen sind.

Big Benefit: YamNet Abschnitte nicht löschen sondern einfach ohne Sprachanteile zur Analyse nutzen. YamNet trotzdem noch als Sicherheitsschicht dahinter lassen

Übertragbarkeit auf die Zielhardware. Die Aufnahmen entstehen mit einem Messmikrofon der Klasse 1, während SIPREMA zwei MEMS-Mikrofone in einem gemeinsamen Gehäuse einsetzt. Beide Ketten unterscheiden sich in Eigenrauschen, Frequenzgang, Dynamikumfang und in der durch das Gehäuse verursachten akustischen Beeinflussung. Die im Experiment ermittelte Rangfolge der Verfahren gilt daher zunächst für Referenzsignalqualität; ihre Übertragbarkeit auf die Zielhardware ist nicht ohne Weiteres

gegeben.

Rechnerische statt akustischer Mischung. Die Superposition nach Gleichung eq:mischmodell bildet die lineare Überlagerung der Schallanteile ab. Nichtlineare Effekte der realen Einsatzumgebung – etwa eine Rückwirkung der Störquelle auf die Maschine oder eine Beeinflussung der Schallausbreitung durch bewegte Objekte – werden nicht erfasst.

Akustische Bedingungen des Messraums. Die kontrollierten Reflexionsverhältnisse des Labors sind Voraussetzung des Verfahrens, weichen jedoch von industriellen Aufstellorten mit ausgeprägtem Nachhall und variablen Reflexionen ab. Die im Labor bestimmte Trennleistung ist daher als obere Schranke zu verstehen.

Zusammensetzung des Störschallinventars. Die vier Störschalltypen decken die in der Anwendung häufigsten Ereignisklassen ab, erheben jedoch keinen Anspruch auf Vollständigkeit gegenüber dem realen Ereignisspektrum industrieller Umgebungen.

Diese Einschränkungen sind dem Untersuchungsziel angemessen: Das Experiment dient dem kontrollierten Vergleich der Verfahren untereinander, nicht der Bestimmung absoluter Leistungswerte für den Feldeinsatz. Zur Einordnung der Laborergebnisse werden diese in Kapitel ?? den Resultaten auf den Felddaten gegenübergestellt.

Das musst du bewusst framen. Mit dem Referenzmikro misst du unter idealen Bedingungen — die Verfahrensrangfolge, die du bekommst, gilt streng genommen für Class-1-Signalqualität.

8.3 Ausblick

- ggf. Erweiterung - Überwachung eines Objektes mit mehreren synchronisierten SIPRE-MA Boxen oder z.B. auch mehrere Mikrofone die alle mit der selben Box verbunden sind? Multi-Mic)
- ggf. Lockerung der Kriterien um Erweiterungen - also mehrere Mikrofone, mehr Rechenleistung usw. ggf. findet sich dann eine Lösung
- ggf. bessere Mikrofone (höhere Qualität, kleiner und näher verbaut usw.)

- Idee ähnlich zu SAM. YAMNet erkennt momentan für Siprema Umgebungsgeräusche wie Vögel oder Stimmen, weil es darauf vortrainiert ist das zu erkennen. Dann wird dieser komplette Geräuschnipsel entfernt wodurch leicher alle Daten weg sind. Wäre es aber auch möglich nur das Störgeräusch zu isolieren? YAMNet erkennt nur die Störgeräusche. Auf dieser Basis dann nicht den Schnipsel mit Störanteil löschen sondern nur das Störgeräusch löschen? <https://github.com/tensorflow/models/blob/master/research/audioset/>
<https://www.tensorflow.org/hub/tutorials/yamnet>
 - Datenverarbeitung nicht on device sondern in der Cloud ? Dann kann man komplexere Modelle verwenden, die ggf. das Problem besser lösen
- Ai Modell feintunen mit dem ganzen Kontext. Dann ein Geräusch übergeben, das Modell hören lassen und dann entscheidet es im Analysemodus welche Methode am besten läuft - z.B: mit Claude?
- Besser für: Rotierende Maschinen mit homogenem Betriebsmuster dynamische Maschinen ohne typische Geräuschmuster Pumpen, Motoren, Förderbänder u.A. > Roboter, CNC?, u.A. ?

8.3.1 Einschränkungen des Aufbaus

Der Aufbau erkaufte die Verfügbarkeit eines Ground Truth mit vier Einschränkungen.

Die Aufnahmen entstehen mit einem Messmikrofon der Klasse 1, während SIPREMA MEMS-Mikrofone in einem gemeinsamen Gehäuse eingesetzt. Beide Ketten unterscheiden sich in Eigenrauschen, Frequenzgang und Gehäuseeinfluss; die ermittelte Verfahrensrangfolge gilt daher zunächst für Referenzsignalqualität.

Die rechnerische Mischung bildet die lineare Überlagerung ab. Nichtlineare Effekte der realen Umgebung – etwa eine Rückwirkung der Störquelle auf die Maschine – werden nicht erfasst.

Die kontrollierten Reflexionsverhältnisse des Labors sind Voraussetzung des Verfahrens, weichen jedoch von industriellen Aufstellorten mit ausgeprägtem Nachhall ab. Die im Labor bestimmte Trennleistung ist daher als obere Schranke zu verstehen.

Schließlich lässt sich die nutzschallfreie Referenzaufnahme nur im Labor gewinnen, da die überwachte Maschine im Feldbetrieb nicht abgeschaltet werden kann. Verfahren, die

auf eine solche Referenz angewiesen sind, werden hier unter günstigeren Bedingungen geprüft als im späteren Einsatz.

Diese Einschränkungen sind dem Untersuchungsziel angemessen: Das Experiment dient dem kontrollierten Vergleich der Verfahren untereinander, nicht der Bestimmung absoluter Leistungswerte für den Feldeinsatz. Zur Einordnung werden die Laborergebnisse ergänzend den Resultaten auf den Felddaten gegenübergestellt, für die kein Ground Truth vorliegt.

Ein aufschlussreicher Befund der Erprobung betrifft das State-Space-Verfahren mit EM-Parameterschätzung. Der EM-Algorithmus optimiert auf maximale Likelihood, also auf eine möglichst vollständige Erklärung des Signals durch das Modell. Dadurch wird der als Nutzschaall rekonstruierte Anteil maximal vollständig, während der Störschaall-Kanal weitgehend leer bleibt – selbst transiente Ereignisse wie ein Schlag werden vom Modell einverleibt. In der Erprobung führte dies zum schwächsten Trennergebnis; der transiente Anteil verblieb nahezu vollständig im Nutzschaall. Dieses Verhalten ist keine Fehlfunktion, sondern eine strukturelle Eigenschaft: Maximale Rekonstruktion und trennscharfe Zerlegung sind gegensätzliche Ziele. Das Verfahren illustriert damit, dass ein gutes Signalmodell nicht notwendigerweise ein gutes Trennverfahren ergibt.

Bemerkenswert ist, dass mehrere methodisch grundverschiedene Verfahren denselben transienten Störanteil isolieren, jedoch über völlig unterschiedliche Prinzipien: HPSS über die vertikale (perkussive) Struktur im Spektrogramm, RPCA über die Sparsität seltener Matrix-Ausreißer, die Wavelet-Zerlegung über große Koeffizienten in feinen Zeitskalen und die Spectral Kurtosis über nicht- gaußförmige, impulsive Frequenzbänder. Dass derart unterschiedliche Ansätze denselben Schlag erfassen, bestätigt dessen Identifizierbarkeit unabhängig vom gewählten Verfahren. Die Unterschiede in der Trennschärfe und darin, welche Anteile jeweils im Nutzschaall verbleiben, bilden einen zentralen Aspekt des Verfahrensvergleichs.

Die Empirical Mode Decomposition fand die dominanten Frequenzkomponenten des Referenzsignals selbstständig wieder, darunter die zuvor identifizierte Grundfrequenz. Dass ein datengetriebenes Zerlegungsverfahren ohne Vorgabe von Frequenzen zu

denselben Komponenten gelangt wie die vorgelagerte Signalanalyse, stützt die Belastbarkeit dieser Analyse.

Innerhalb der statistischen Spektralschätzung lässt sich eine Abstufung der spektralen Dämpfung erkennen. Die Spektralsubtraktion subtrahiert hart und erzeugt dabei die stärksten Artefakte („Musical Noise“). Der Wiener-Filter wendet eine weiche, im quadratischen Mittel optimale Verstärkung an und reduziert dadurch Artefakte. Der MMSE-STSA-Schätzer verfeinert dies über einen Bessel-basierten Verstärkungsfaktor. Die drei Verfahren bilden damit eine konzeptionelle Reihe von der harten zur zunehmend feineren spektralen Dämpfung.

Der Vergleich adaptiver Filter zeigt den klassischen Gegensatz zwischen LMS und RLS: RLS konvergiert deutlich schneller und ist unempfindlich gegenüber der Wahl der Schrittweite, kostet jedoch quadratischen statt linearen Aufwand pro Abtastwert. Durch die schnelle Anpassung legt RLS die Referenz nahezu momentanoptimal an, wodurch der rekonstruierte Nutzschall kleiner ausfällt als bei LMS. Der eigentliche Erkenntniswert liegt in diesem Trade-off zwischen Konvergenzgeschwindigkeit und Selektivität beziehungsweise Rechenaufwand.

Mehrkanalverfahren wie die Generalisierte Eigenwertzerlegung wurden nicht empirisch erprobt, da sie im SIPREMA-Kontext nicht schlechter, sondern mathematisch nicht definiert sind: Ihnen fehlt die zweite räumliche Dimension, die zur Bildung einer sinnvollen Kanal-Kovarianzmatrix erforderlich ist. Anders als etwa das State-Space-Verfahren, das empirisch getestet und als schwach befunden werden konnte, gibt es bei diesen Verfahren nichts zu testen – jede Erprobung müsste das Einkanalsignal künstlich in Pseudo-Kanäle aufsplitten und wäre damit kein Mehrkanalverfahren im eigentlichen Sinn mehr. Der Ausschluss erfolgt hier also durch physikalische Unmöglichkeit, nicht durch mangelnde Trennleistung.

Die Rauschschätzung der statistischen Spektralverfahren stützt sich auf einen kontrolliert nutzschallfreien Referenzabschnitt, der bei stillstehender Maschine aufgezeichnet wird. Dieses Vorgehen ist im Prüfstands- und Experimentkontext unproblematisch, im späteren Feldbetrieb jedoch nur eingeschränkt übertragbar, da eine überwachte Maschine dort nicht ohne Weiteres zur Referenzaufnahme abgeschaltet werden kann. Für den Produktivbetrieb wäre daher ein Mechanismus erforderlich, der stillstands-

oder störschalldominierte Abschnitte automatisch erkennt.

Deep-Learning-Modelle zur Audioquellentrennung sind hinsichtlich der Kriterien K1 bis K4 gesondert einzuordnen. Sie sind auf umfangreichen Datensätzen trainiert (im Widerspruch zu K3), überwiegend für Musik-Stems oder Sprache konzipiert und nicht auf Maschinennutzschall spezialisiert, und setzen für die Inferenz meist GPU-Ressourcen voraus (K1). Es ist zu erwarten, dass sie bei der reinen Trennqualität überzeugen, an den Eignungskriterien jedoch scheitern. Sie werden daher nicht als K1–K4-konforme Kandidaten geführt, sondern als externe Referenz beziehungsweise obere Vergleichsmarke, an der sich die klassischen Verfahren messen lassen.

SAM Audio ist ein generatives, promptgesteuertes Modell. Als generatives Verfahren kann es Signalkomponenten erzeugen, die im ursprünglichen Signal nicht enthalten waren – im Gegensatz zu den klassischen Verfahren, die vorhandene Signalanteile lediglich umverteilen. Die Ausgaben sind daher kritisch zu prüfen: Klingt der extrahierte Nutzschall sauberer, als es physikalisch plausibel ist, deutet dies auf eine generative Ergänzung und nicht auf eine signaltreue Trennung hin. Generative Trennung und signaltreue Trennung sind konzeptionell zu unterscheiden.

Demucs ist ein auf Musikquellen trainiertes Modell (Hybrid Transformer Demucs), das Stems wie Vocals, Drums und Bass vom Rest trennt. Es dient hier ausschließlich als Benchmark-Obergrenze. Da das Modell zwei Eingangskanäle erwartet, wird das einkanalige Signal auf Stereo dupliziert und die Ausgabe zurück auf einen Kanal gemittelt; es wird also technisch ein künstliches Stereo-Signal verarbeitet. Die Einordnung in das Nutz-/Störschall-Schema erfolgt über den Zwei-Stems-Modus (ein gewählter Stem gegenüber dem Rest) und ist als bewusste Zweckentfremdung eines Musikmodells zu kennzeichnen.

Als Deep-Learning-Referenzen wurden Demucs und SAM Audio erfolgreich evaluiert. Ein dritter Kandidat (AudioSep) konnte im Zielumfeld nicht in Betrieb genommen werden: Die veralteten, hart versionierten Abhängigkeiten des Modells ließen sich weder mit der aktuellen Python-Umgebung noch im abgeschotteten Firmennetz auflösen (u. a. Binärkonflikte der ML-Bibliotheken und fehlgeschlagene Quellkompilierung nativer Pakete). Dieser Umstand illustriert exemplarisch die in K1/K3 bewerteten Deployment-Hürden datengetriebener Verfahren gegenüber den klassischen, abhängigkeitsarmen

Signalverarbeitungsmethoden.

Ergänzend zeigte sich, dass auch eine Signaltrennung mithilfe großer Sprachmodelle praktikabel ist. Die Modelle griffen zur Lösung der Aufgabe jedoch durchgängig auf klassische Algorithmen wie HPSS und NMF zurück. Dies stützt die Annahme, dass die etablierten signalverarbeitenden Verfahren den Kern der Trennung tragen und auch von datengetriebenen Werkzeugen nicht durch grundlegend neue Trennprinzipien ersetzt, sondern lediglich orchestriert werden.

Literatur

- ADOBE INC., 2025. *Enhance Speech – AI Audio Filter for Spoken Audio* [Webseite]. Auch verfügbar unter: <https://podcast.adobe.com/enhance>. Abgerufen am 26.05.2026.
- ANTONI, Jérôme, 2009. Cyclostationarity by examples. *Mechanical Systems and Signal Processing*. Jg. 23, Nr. 4, S. 987–1036. Abger. unter DOI: 10.1016/j.ymssp.2008.10.010.
- BELOUCHRANI, Adel; ABED-MERAIM, Karim; CARDOSO, Jean-François; MOULINES, Eric, 1997. A Blind Source Separation Technique Using Second-Order Statistics. *IEEE Transactions on Signal Processing*. Jg. 45, Nr. 2, S. 434–444. Abger. unter DOI: 10.1109/78.554307.
- BOLL, Steven F., 1979. Suppression of Acoustic Noise in Speech Using Spectral Subtraction. In: IEEE. Bd. 27, S. 113–120. Nr. 2. Abger. unter DOI: 10.1109/TASSP.1979.1163209.
- CANDÈS, Emmanuel J.; LI, Xiaodong; MA, Yi; WRIGHT, John, 2011. Robust Principal Component Analysis? *Journal of the ACM*. Jg. 58, Nr. 3, S. 1–37. Abger. unter DOI: 10.1145/1970392.1970395.
- COCHL INC., 2025. *Cochl.Sense – Edge SDK for Sound AI* [Webseite]. Auch verfügbar unter: <https://www.cochl.ai>. Abgerufen am 26.05.2026.
- DRAGOMIRETSKIY, Konstantin; ZOSSO, Dominique, 2014. Variational Mode Decomposition. *IEEE Transactions on Signal Processing*. Jg. 62, Nr. 3, S. 531–544. Abger. unter DOI: 10.1109/TSP.2013.2288675.

- DRIEDGER, Jonathan; MÜLLER, Meinard; DISCH, Sascha, 2014. Extending Harmonic-Percussive Separation of Audio Signals. In: *Proceedings of the 15th International Society for Music Information Retrieval Conference (ISMIR)*. Taipei, Taiwan, S. 611–616.
- EPHRAIM, Yariv; MALAH, David, 1984. Speech Enhancement Using a Minimum Mean-Square Error Short-Time Spectral Amplitude Estimator. *IEEE Transactions on Acoustics, Speech, and Signal Processing*. Jg. 32, Nr. 6, S. 1109–1121. Abger. unter DOI: 10.1109/TASSP.1984.1164453.
- ERNST & SOHN GMBH, 2023. *Literaturverzeichnisse nach DIN ISO 690 – Beispielsammlung*. Auch verfügbar unter: <https://www.ernst-und-sohn.de/sites/default/files/beispielsammlung-literaturverzeichnis.pdf>. Stand: 17. März 2023. Abgerufen am 18. Mai 2026.
- FITZGERALD, Derry, 2010. Harmonic/Percussive Separation Using Median Filtering. In: *Proceedings of the 13th International Conference on Digital Audio Effects (DAFx-10)*. Graz, Austria, S. 246–253.
- FRAUNHOFER INSTITUT FÜR DIGITALE MEDIENTECHNOLOGIE IDMT, 2023. *Industrial Sound Analysis – AI-Based Acoustic Monitoring of Products and Processes* [Webseite]. Auch verfügbar unter: <https://www.idmt.fraunhofer.de/en/research-topics/industrial-sound-analysis.html>. Abgerufen am 26.05.2026.
- GEMMEKE, Jort F.; ELLIS, Daniel P. W.; FREEDMAN, Dylan; JANSEN, Aren; LAWRENCE, Wade; MOORE, R. Channing; PLAKAL, Manoj; RITTER, Marvin, 2017. Audio Set: An Ontology and Human-Labeled Dataset for Audio Events. In: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, S. 776–780. Abger. unter DOI: 10.1109/ICASSP.2017.7952261.
- GROLLMISCH, Sascha; ABESSER, Jakob; LIEBETRAU, Judith; LUKASHEVICH, Hanna, 2019. Sounding Industry: Challenges and Datasets for Industrial Sound Analysis. In: *2019 27th European Signal Processing Conference (EUSIPCO)*. IEEE, S. 1–5. Abger. unter DOI: 10.23919/EUSIPCO.2019.8902666.
- HERSHEY, Shawn; CHAUDHURI, Sourish; ELLIS, Daniel P. W.; GEMMEKE, Jort F.; JANSEN, Aren; MOORE, R. Channing; PLAKAL, Manoj; PLATT, Devin; SAUROUS, Rif A.; SEYBOLD, Bryan; SLANEY, Malcolm; WEISS, Ron J.; WILSON, Kevin, 2017.

- CNN Architectures for Large-Scale Audio Classification. In: *Proceedings of the IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*. IEEE, S. 131–135. Abger. unter DOI: 10.1109/ICASSP.2017.7952132.
- HIRSCHMILLER, Michael; SCHLOSSER, Kevin; RÖSSLE, Manfred; FERNANDES, Marc, 2023a. Design and Prototype Development of an AI-Based Application for Predictive Maintenance Using Smart Device and Airborne Noise Data. *Procedia Computer Science*. Jg. 225, S. 486–495. ISSN 1877-0509. Abger. unter DOI: 10.1016/j.procs.2023.10.033.
- HIRSCHMILLER, Michael; SCHLOSSER, Kevin; RÖSSLE, Manfred; FERNANDES, Marc, 2023b. Design and Prototype Development of an AI-Based Application for Predictive Maintenance Using Smart Device and Airborne Noise Data. *Procedia Computer Science*. Jg. 225, S. 486–495. Abger. unter DOI: 10.1016/j.procs.2023.10.033. 27th International Conference on Knowledge-Based and Intelligent Information & Engineering Systems (KES 2023).
- JOMBO, G. u. a., 2023. Acoustic-Based Machine Condition Monitoring—Methods and Challenges. *Eng. Jg.* 4, Nr. 1, S. 56–89. Abger. unter DOI: 10.3390/eng4010004.
- KAMAT, Pooja; SUGANDHI, Rekha, 2020. Anomaly Detection for Predictive Maintenance in Industry 4.0: A Survey. In: *E3S Web of Conferences*. Bd. 170, S. 02007. Abger. unter DOI: 10.1051/e3sconf/202017002007.
- KO, Seok-Bum; RUTENBAR, Rob A., 2018. Real-Time and Low-Power Streaming Source Separation Using Markov Random Field. In: *2018 IEEE International Symposium on Circuits and Systems (ISCAS)*. Piscataway, NJ: IEEE, S. 1–5. Abger. unter DOI: 10.1109/ISCAS.2018.8351099.
- KRISP TECHNOLOGIES, 2025. *Krisp – AI-Powered Noise Cancellation* [Webseite]. Auch verfügbar unter: <https://krisp.ai>. Abgerufen am 26.05.2026.
- LEE, Daniel D.; SEUNG, H. Sebastian, 2000. Algorithms for Non-negative Matrix Factorization. In: *Advances in Neural Information Processing Systems*. Cambridge, MA: MIT Press. Bd. 13, S. 556–562. Auch verfügbar unter: <https://proceedings.neurips.cc/paper/2000/hash/f9d1152547c0bde01830b7e8bd60024c-Abstract.html>.

LEHRSTUHL FÜR DIGITALES MANAGEMENT, UNIVERSITÄT HOHENHEIM, 2025.

Methodenvermittlung wissenschaftliches Arbeiten. Auch verfügbar unter: <https://digital.uni-hohenheim.de/methodenvermittlung-wissenschaftliches-arbeiten>. Zuletzt aktualisiert: 10. Oktober 2025. Abgerufen am 18. Mai 2026.

LERCH, Reinhard; SESSLER, Gerhard; WOLF, Dietrich, 2009. *Technische Akustik: Grundlagen und Anwendungen*. Berlin, Heidelberg: Springer Berlin Heidelberg. ISBN 978-3-540-49833-9. Abger. unter DOI: 10.1007/978-3-540-49833-9.

LI, Guang-Lai, 2022. A Unifying Framework for Blind Source Separation Algorithms Based on Generalized Eigenvalue Decomposition. *IEEE Access*. Jg. 10, S. 87279–87290. Abger. unter DOI: 10.1109/ACCESS.2022.3199969.

LIU, Xubo; KONG, Qiuqiang; ZHAO, Yan; LIU, Haohe; YUAN, Yi; LIU, Yuzhuo; XIA, Rui; WANG, Yuxuan; PLUMBLEY, Mark D.; WANG, Wenwu, 2023. *Separate Anything You Describe*. Auch verfügbar unter: <https://ui.adsabs.harvard.edu/abs/2025ITASL..33..458L/abstract>.

META AI, 2025. *SAM Audio – Segment Anything in Audio* [Webseite]. Auch verfügbar unter: <https://ai.meta.com/research/samaudio/>. Abgerufen am 26.05.2026.

MOLGEDEY, Lutz; SCHUSTER, Heinz Georg, 1994. Separation of a Mixture of Independent Signals Using Time Delayed Correlations. *Physical Review Letters*. Jg. 72, Nr. 23, S. 3634–3637. Abger. unter DOI: 10.1103/PhysRevLett.72.3634.

NVIDIA CORPORATION, 2025. *NVIDIA Broadcast – AI-Powered Noise Removal* [Webseite]. Auch verfügbar unter: <https://www.nvidia.com/en-us/geforce/broadcasting/broadcast-app/>. Abgerufen am 26.05.2026.

OLSSON, Rickard K.; HANSEN, Lars K., 2006. Linear State-Space Models for Blind Source Separation. *Journal of Machine Learning Research*. Jg. 7, S. 2585–2602. Auch verfügbar unter: <https://jmlr.org/papers/v7/olsson06a.html>.

OMLOR, Lars; GIESE, Martin A., 2011. Anechoic Blind Source Separation Using Wigner Marginals. *Journal of Machine Learning Research*. Jg. 12, S. 1111–1148. Auch verfügbar unter: <https://jmlr.org/papers/v12/omlor11a.html>.

- PARRA, Lucas; SAJDA, Paul, 2003. Blind Source Separation via Generalized Eigenvalue Decomposition. *Journal of Machine Learning Research*. Jg. 4, S. 1261–1269. Auch verfügbar unter: <https://jmlr.org/papers/v4/parra03a.html>.
- PICHLER, Christof; NEUMAYER, M.; SCHWEIGHOFER, B.; FEILMAYR, C.; SCHUSTER, S.; WEGLEITER, H., 2024. Knocking Sound Detection for Acoustic Condition Monitoring in Industrial Facilities. *IEEE Sensors Letters*. Jg. 8, Nr. 10, S. 1–4. Abger. unter DOI: 10.1109/LSENS.2024.3445162. Art. no. 6013004.
- PIEPIORKA, Joscha; KRANZ, Ole; WURM, Frank-Hendrik; ESTORFF, Otto von, 2019. Numerische Simulation und Untersuchung des Strömungsschalls in einer Radialpumpe. In: *Fortschritte der Akustik – DAGA 2019*. Rostock, Deutschland: Deutsche Gesellschaft für Akustik e.V. (DEGA), S. 986–989. ISBN 978-3-939296-14-0. Auch verfügbar unter: https://pub.dega-akustik.de/DAGA_2019/data/articles/000043.pdf.
- RANDALL, Robert Bond, 2011. *Vibration-Based Condition Monitoring: Industrial, Aerospace and Automotive Applications*. Chichester, UK: John Wiley & Sons. ISBN 9780470747858. Abger. unter DOI: 10.1002/9780470977668.
- RÖWAPLAN AG, 2026. SIPREMA [online]. [besucht am 2026-03-31]. Abger. unter: <https://www.siprema.de/>. Zugriff am 31.03.2026 und Webinar am 17.03.
- SCHMITT, Sebastian; GUPTA, Anmol, 2024. Continuous Learning for Real-Time Auditory Blind Source Separation Applications. In: *Proceedings of the 2024 IEEE International Symposium on Circuits and Systems (ISCAS)*. Piscataway, NJ: IEEE. Abger. unter DOI: 10.1109/ISCAS58744.2024.10558292.
- SCHWARTZ, Ofer; GANNOT, Sharon; HABETS, Emanuel A. P., 2017. Two Model-Based EM Algorithms for Blind Source Separation in Noisy Environments. *IEEE/ACM Transactions on Audio, Speech, and Language Processing*. Jg. 25, Nr. 5, S. 1072–1085. Abger. unter DOI: 10.1109/TASLP.2017.2682226.
- SOUND GENETICS INC., 2025. *Edge-Native Acoustic Intelligence Platform* [Webseite]. Auch verfügbar unter: <https://www.soundgeneticsinc.com/platform>. Abgerufen am 26.05.2026.

- TORRE-CRUZ, Javier; CANADAS-QUESADA, Francisco J.; VERA-CANDEAS, Pedro; RUIZ-REYES, Nicolas; CARABIAS-ORTI, Julio J., 2018. Wheezing Sound Separation Based on Constrained Non-Negative Matrix Factorization. *Biomedical Signal Processing and Control*. Jg. 39, S. 75–84. Abger. unter DOI: 10.1016/j.bspc.2017.07.013.
- TORUN, Kadir; SERT, Mustafa, 2025. A Hybrid Noise Perturbation-Based Denoising Autoencoder for Machine Sound Anomaly Detection. In: *2025 International Symposium on Multimedia (ISM)*. Piscataway, NJ: IEEE, S. 354–357. Abger. unter DOI: 10.1109/ISM66958.2025.00072.
- UBER, Heiner, 1994. Ein Ohr in die Zukunft. *Die Zeit*. Nr. 46. Auch verfügbar unter: <https://www.zeit.de/1994/46/ein-ohr-in-die-zukunft/komplettansicht>.
- VESTER, Frederic, 2002. *Die Kunst vernetzt zu denken: Ideen und Werkzeuge für einen neuen Umgang mit Komplexität*. 2. Aufl. München: Deutsche Verlags-Anstalt.
- VIRTANEN, Tuomas, 2007. Monaural Sound Source Separation by Nonnegative Matrix Factorization With Temporal Continuity and Sparseness Criteria. *IEEE Transactions on Audio, Speech, and Language Processing*. Jg. 15, Nr. 3, S. 1066–1074. Abger. unter DOI: 10.1109/TASL.2006.885253.
- WEBSTER, Jane; WATSON, Richard T., 2002. Analyzing the Past to Prepare for the Future: Writing a Literature Review. *Management Information Systems Quarterly*. Jg. 26, Nr. 2, S. xiii–xxiii. ISSN 0276-7783. Abger. unter DOI: 10.2307/4132319.
- WIDROW, Bernard; GLOVER, John R.; MCCOOL, John M.; KAUNITZ, John; WILLIAMS, Charles S.; HEARN, Robert H.; ZEIDLER, James R.; DONG, Eugene; GOODLIN, Robert C., 1975. Adaptive noise cancelling: Principles and applications. *Proceedings of the IEEE*. Jg. 63, Nr. 12, S. 1692–1716. Abger. unter DOI: 10.1109/PROC.1975.10036.
- WU, Jian-Da; WU, Meng-Jhang, 2018. Speech Enhancement Using Successive State Estimation under Industrial Noise Environment. *Applied Acoustics*. Jg. 129, S. 40–49. Abger. unter DOI: 10.1016/j.apacoust.2017.07.008.

- YAMATO, Yoji; FUKUMOTO, Yoshifumi; KUMAZAKI, Hiroki, 2017. Predictive Maintenance Platform with Sound Stream Analysis in Edges. *Journal of Information Processing*. Jg. 25, S. 317–320. Abger. unter DOI: 10.2197/ipsjjip.25.317. Technical Note.
- YEREDOR, Arie, 2011. Performance Analysis of GEVD-Based Source Separation With Second-Order Statistics. *IEEE Transactions on Signal Processing*. Jg. 59, Nr. 10, S. 5077–5082. Abger. unter DOI: 10.1109/TSP.2011.2160864.

Anhang

A.1 Suchstring-Katalog

Tabelle A.1: Suchstring-Katalog der strukturierten Literaturrecherche

Nr.	Cluster	Sprache	Suchstring	Treffer
1	A×B	EN	"acoustic condition monitoring" AND "noise reduction"	–
2	A×B	EN	"predictive maintenance" AND "background noise" AND "sound"	–
3	A×B	EN	"airborne sound" AND ("source separation" OR "noise reduction")	–
4	A×B	EN	"industrial noise" AND ("blind source separation" OR "spectral subtraction")	–
5	B	EN	"spectral subtraction" AND "background noise estimation"	–
6	B	EN	"blind source separation" AND ("audio" OR "acoustic")	–
7	B	EN	"deep learning" AND "denoising" AND "acoustic"	–

Fortsetzung auf nächster Seite

Fortsetzung von vorheriger Seite

Nr.	Cluster	Sprache	Suchstring	Treffer
8	B	EN	"non-negative matrix factorization" AND ("audio" OR "acoustic")	–
9	B×C	EN	"noise reduction" AND ("edge computing" OR "embedded system") AND "audio"	–
10	A×B×C	EN	"anomaly detection" AND "acoustic" AND "noise reduction" AND "edge"	–
11	A×C	EN	"acoustic monitoring" AND ("edge computing" OR "embedded system")	–
12	A×C	EN	"predictive maintenance" AND ("Raspberry Pi" OR "edge device") AND "sound"	–
13	A×B	DE	"akustische Zustandsüberwachung" AND "Geräuschreduktion"	–
14	A×B	DE	"Predictive Maintenance" AND "Hintergrundgeräusch" AND "Schall"	–
15	B	DE	"Spektrale Subtraktion" AND "Signalverarbeitung"	–
16	B	DE	"Quelltrennung" AND ("Audio" OR "Akustik")	–
17	B×C	DE	"Rauschreduktion" AND ("Embedded System" OR "Edge Computing")	–
18	A×B×C	DE	"Anomalieerkennung" AND "akustisch" AND "Rauschreduktion"	–

Cluster A – Zielsignal/Anwendung: *acoustic condition monitoring, predictive maintenance, machine sound, airborne sound, industrial noise*

Cluster B – Verfahren: *noise reduction, source separation, blind source separation, spectral subtraction, background noise estimation, non-negative matrix factorization, deep learning denoising*

Cluster C – Kontext/System: *edge computing, embedded system, resource-constrained, Raspberry Pi, microcontroller*

A.2 Datenbanken-Ergebnisse

ACM Digital Library Die Suche ergab 2061 Ergebnisse, davon wurden 27 genauer gesichtet, 10 gespeichert und 5 als zentral priorisiert.

Elsevier Scopus Die Suche ergab 1510 Ergebnisse, davon wurden 7 genauer gesichtet, 3 gespeichert und 1 als zentral priorisiert.

IEEE Xplore Die Suche ergab 1468 Ergebnisse, davon wurden 14 genauer gesichtet, 9 gespeichert und 4 als zentral priorisiert.

JSTOR Die Suche ergab 153 Ergebnisse, davon wurden 4 genauer gesichtet, keine gespeichert und keine als zentral priorisiert.

SpringerLink Die Suche ergab 1581 Ergebnisse, davon wurden 4 genauer gesichtet, 2 gespeichert und 1 als zentral priorisiert.

Wiley Online Library Die Suche ergab 1168 Ergebnisse, davon wurden 2 genauer gesichtet, 1 gespeichert und keine als zentral priorisiert.

A.3 Ergebnisse der Rückwärtssuche

Für die Rückwärtssuche wurden Parra u. a. (2003), Li (2022), Ko u. a. (2018) sowie Torre-Cruz u. a. (2018) gewählt. Die Auswahl begründet sich darin, dass diese vier Arbeiten die zentralen Konzepte – GEVD-basierte BSS, NMF-basierte Einzelkanaltrennung und ressourcenbeschränkte Hardware – abdecken und mit hoher Wahrscheinlichkeit Grundlagenwerke referenzieren.

Die Publikationen verweisen gemeinsam auf insgesamt 121 Referenzen. Diese wurden zunächst anhand des Titels geprüft. Anschließend wurden 15 Arbeiten anhand des

Abstracts näher gesichtet, 12 gespeichert und näher ausgewertet, 5 davon als relevant priorisiert.

A.4 Bewertung der identifizierten Verfahren

Tabelle A.2: Bewertung der identifizierten Verfahren anhand der Auswahlkriterien K1–K4. ✓ = erfüllt, ~ = bedingt erfüllt, ✗ = nicht erfüllt. Ein Verfahren gilt als Kandidat, wenn es alle Kriterien K1–K4 erfüllt (fett hervorgehoben). Die Spalte „Auswahl“ kennzeichnet mit ✓ jene Verfahren, die als Vertreter ihrer Klasse für die vertiefte Implementierung ausgewählt wurden (vgl. Abschnitt 4.2).

Verfahren	Quelle	K1	K2	K3	K4	Auswahl
<i>Physikalisch orientierte Verfahren</i>						
Synchrone Mittelung	McFadden1987	✓	✓	✓	✓	✓
Bandpass-/Kammfilterung	Randall (2011)	✓	✓	✓	✓	
Zyklostationäre Analyse	Antoni (2009)	✓	✓	✓	✓	
Wahrnehmungsbasiert	Baumann1995	✓	✓	✓	✓	
<i>Statistische Spektralschätzung</i>						
Spektralsubtraktion	Boll (1979)	✓	✓	✓	✓	✓
Wiener-Filter	Wiener1949	✓	✓	✓	✓	✓
MMSE-STSA	Ephraim u. a. (1984)	✓	✓	✓	✓	✓
Kalman-Filter	Wu u. a. (2018)	✓	✓	✗	✓	
State-Space + EM	Olsson u. a. (2006)	✗	✓	✗	✗	
<i>Mehrkanalige Quellentrennung (BSS / GEVD)</i>						
GEVD-BSS	Parra u. a. (2003)	✓	✗	✓	✓	
GEVD-Framework	Li (2022)	✓	✗	✓	✓	
SOBI	Belouchrani u. a. (1997)	✓	✗	✓	✓	

Fortsetzung auf nächster Seite

Fortsetzung von vorheriger Seite

Verfahren	Quelle	K1	K2	K3	K4	Auswahl
Zeitverzög. Dekorrelation	Molgedey u. a. (1994)	✓	✗	✓	✓	
GEVD-Performanzanalyse	Yeredor (2011)	✓	✗	✓	✓	
MVDR + Wiener	Schwartz u. a. (2017)	✗	✗	✓	✓	
Adaptive Noise Cancelling	Widrow u. a. (1975)	✓	✗	✓	✓	
<i>Struktur- und Faktorisierungsverfahren</i>						
HPSS	Fitzgerald (2010)	✓	✓	✓	✓	✓
NMF	Virtanen (2007)	✓	✓	✓	✓	✓
RPCA	Candès u. a. (2011)	✓	✓	✓	✓	✓
NMF + Wigner	Omlor u. a. (2011)	✗	✓	✓	~	
<i>Adaptive Modenzerlegung</i>						
VMD	Dragomiretskiy u. a. (2014)	✓	✓	✓	✓	✓
<i>KI-basierte Verfahren</i>						
SAM Audio	Meta AI (2025)	✗	✓	✗	✓	~
AudioSep	Liu u. a. (2023)	✗	✓	✗	✓	
Denoising Autoencoder	Torun u. a. (2025)	✓	✓	✗	~	
Density Network Denoising	Schmitt u. a. (2024)	✓	✓	✗	~	

Die KI-basierten Verfahren erfüllen die Kriterien K1–K4 nicht und sind daher keine regulären Kandidaten. SAM Audio wird abweichend (~) als gesetzte externe Referenz im Experiment geführt; die Begründung liegt in der Aktualität des Modells und der breiten Forschungsbasis promptgesteuerter Foundation-Modelle (vgl. Abschnitt 4.2).

A.5 Verfahrenscod

Anhang Hs Aalen Eigenständigkeitderklärung KI - Claude auflisten für Grafiken, Übersetzungen, Codeoptimierung und Erstellung großer Latex Tabellen usw.